Drifting as a Flow Map sur CelebA-64

Structure, entraînement, temps de calcul et résultats

Rapport fondé sur les artefacts audités du dépôt
15 septembre 2026

Résultat principal actuel, RGB direct sans VAE. Le meilleur Flow–GMD audité part du checkpoint structurel E10 à 5,000 updates et ajoute seulement 50 updates à learning rate 5×10^{-6}, avec une vraie transition feature–GMD locale de poids 0.005. Sur trois graines de génération, les poids bruts atteignent $\mathbf{7.8012 \pm 0.0008}$ de FID à NFE 1, $\mathbf{7.5574 \pm 0.0006}$ à NFE 2 et $\mathbf{7.5499 \pm 0.0010}$ à NFE 16. Les KID correspondants sont 0.0028401, 0.0026512 et 0.0026416. FID et KID battent E10–5k dans les trois graines aux trois budgets. L'ablation appariée montre cependant que la courte continuation à faible learning rate explique la majeure partie du gain FID absolu ; la loss locale apporte surtout le gain KID et les gains causaux robustes à NFE 1 et NFE 16. Cette nouvelle branche n'a encore qu'une graine d'entraînement.

Résultat historique latent. Dans la confirmation CelebA latente historique à trois graines, la méthode retenue Core C atteint un FID de $\mathbf{45.762 \pm 1.513}$ avec quatre appels à la flow map, contre 66.020 ± 1.002 pour l'ancien baseline KDE–WGF latent avec un appel. Le même modèle Core C donne 61.556 ± 0.590 avec un seul appel : l'amélioration appariée de un à quatre appels est donc -15.793 ± 0.927 points de FID.

Point essentiel sur le VAE. Le VAE n'est pas entraîné avec la flow map. Il est préentraîné, gelé, puis utilisé une fois pour encoder CelebA et, après entraînement, pour décoder les latents générés. Seule la flow map reçoit des gradients.

Temps observé. Sur huit GPU AMD Instinct MI210, 5,000 mises à jour prennent en moyenne 327.97 ± 5.78 secondes dans le trainer pour Core C, contre 180.26 ± 8.62 secondes pour le baseline KDE–WGF latent. Les temps de job Slurm complets sont plus longs et sont rapportés séparément.

Mise à jour GMD sans VAE. Dans un screen causal mono-graine, ajouter les 13 familles gelées de ConvNeXt-V2 Base aux 82 familles du MAE, sans autre changement, abaisse le FID RGB direct de 53.262 à **18.887** à 10k updates. Le KID passe de 0.044640 à 0.008841. La gate préenregistrée est donc **GO**. Ce résultat très favorable reste mesuré sur le holdout local de développement, pas sur le test officiel CelebA.

Première validation officielle GMD. Sur les 19,867 images de la validation officielle, le GMD RGB direct sans VAE au checkpoint 25k obtient un FID de 45.716 avec les poids bruts et de **37.943** avec l'EMA, à NFE 1. Le KID passe respectivement de 0.040981 à **0.034372**. Les trois jobs raw, EMA et agrégat sont terminés `COMPLETED/0:0`, sans redémarrage, et le split test reste scellé. Ce diagnostic mono-graine n'est pas une sélection finale d'endpoint.

Protocole commun final, sans VAE ni latent. La comparaison directe-RGB utilise maintenant les mêmes 19,867 images de validation et le même extracteur PyTorch-FID. Au checkpoint 50k, le drifting/GMD obtient un FID de 40.095945 en brut et de **35.230066** en EMA. Les 20 cellules Flow Maps au checkpoint 25k (deux layouts, brut/EMA, NFE 1/2/4/8/16) sont toutes terminées. Leur meilleur résultat est le layout stratifié brut : FID 374.801540, KID 0.500694628 dans la cellule NFE 2. Le minimum KID, numériquement presque identique, est 0.500694627 à NFE 1. Le meilleur layout release brut vaut 423.422679. L'EMA dégrade les deux layouts et changer NFE ne modifie pratiquement pas les résultats bruts. Ce constat est fort pour ces checkpoints, mais la comparaison n'est pas normalisée par le nombre d'updates ni par le calcul d'entraînement. Un balayage temporel complémentaire de 24 points, à NFE 1, situe désormais le meilleur résultat observé à 5k updates pour le layout stratifié brut : FID 336.106247, KID 0.430355872. Les courbes oscillent fortement jusqu'à 35k. Cette non-monotonie est un diagnostic d'optimisation précoce, mais **elle ne réfute pas le sous-entraînement** : 35k ne représente que 4.375% du budget papier de 800k et le learning rate commence seulement sa décroissance à ce point. Une EMA plus réactive, 0.999, améliore l'EMA 0.9999 dans 11 checkpoints sur 12 en FID, mais son meilleur FID reste 372.514402 et les poids bruts restent globalement préférables. Enfin, un balayage NFE ciblé sur les deux meilleurs checkpoints confirme que NFE 1 minimise le FID ; NFE 2 ne gagne que 0.000512669 de KID sur stratifié 5k, au prix de +2.425290 FID, puis NFE 4/8/16 dégradent conjointement qualité et diversité.

Distinction entre les deux flow maps RGB. Les FID 336–375 ci-dessus appartiennent à l'ancienne recette LSD directe, avec son architecture et son objectif propres. Ils ne décrivent pas le Flow–GMD E10 actuel, initialisé depuis le générateur GMD 60k et évalué avec les features MAE–82+ConvNeXt–13. Ce second pipeline atteint des FID proches de 7.55 et fait l'objet de la section 11.12.

Résultat flow map D4. Une ablation préenregistrée reprend le même checkpoint LSD 30k et divise l'ancrage terminal GMD par deux. Le brut reste meilleur que LSD pur à toutes les NFE, mais à NFE 16 l'EMA dépasse le contrôle de seulement 0.00654 FID et 1.41×10^{-5} KID. Les portes étant strictes et conjointes, le verdict formel est `NO_GO` : D4 réduit presque entièrement le défaut EMA de D2, sans l'annuler exactement.

Table des matières

1 Réponse courte : qu'est-ce qui a été fait ? 5

2 Pipeline complet et place exacte du VAE 6

2.1 Vue d'ensemble 6

2.2 Le VAE n'a pas été entraîné conjointement . . . 6
2.3 Données et séparation utilisée . . . 6

3 Structure de la flow map **8**
3.1 Réseau . . . 8
3.2 Paramétrisation qui impose l'identité . . . 8
3.3 NFE à l'inférence . . . 8

4 Champ de drifting et bandwidth **9**

5 Loss de la méthode CelebA retenue **9**
5.1 1. Endpoint drifting : apprendre la destination . . . 9
5.2 2. Deux résidus WGF : apprendre une direction . . . 9
5.3 3. Composition : rendre la transition réutilisable . . . 10
5.4 Somme réellement optimisée : Core C . . . 10
5.5 Baseline KDE–WGF historique utilisé comme référence . . . 10

6 Comment l'entraînement a été exécuté **10**
6.1 Deux phases, et non un entraînement VAE + flow simultané . . . 10
6.2 Une itération de Core C, pas à pas . . . 11
6.3 Configuration exacte de la confirmation finale . . . 11

7 Protocole d'évaluation **11**

8 Résultats principaux sur CelebA latent **12**
8.1 Lecture directe du tableau . . . 12
8.2 Résultats qualitatifs . . . 14

9 Temps d'entraînement mesurés **14**
9.1 Deux mesures différentes . . . 14

10 Pourquoi le latent était nécessaire dans le pipeline testé **14**
10.1 Contrôles du codec et du prior . . . 14
10.2 Comparaison historique directement dans les pixels . . . 15
10.3 Interprétation prudente . . . 15

11 Mise à jour : le GMD canonique sur les images **16**
11.1 Que signifie GMD ? . . . 16
11.2 Ce que la littérature établit réellement . . . 16
11.3 Résultats GMD locaux déjà mesurés . . . 17
11.4 Validation officielle du GMD RGB à 25k . . . 17

11.5 Recette Flow Maps publiée sur CelebA-64 18
11.6 Comparaison finale dans un protocole commun direct-RGB 19
11.7 Ne pas confondre les deux protocoles FID déjà exécutés 20
11.8 Trajectoire des checkpoints Flow Maps, de 5k à 35k 21
11.9 Effet causal de ConvNeXt dans le screen RGB 25
11.10Diagnostic post-hoc du noyau GMD 26
11.11Reprise de la flow map : pilotes D2 et D4 26
11.12E10 + transition GMD locale vraie courte 27
11.13Priorités expérimentales après l'audit 29

12 Diagnostics : que résout réellement la méthode ? 29

13 Lien avec MNIST et les mélanges de Gaussiennes 29

14 Conclusions scientifiquement défendables 31

A Valeurs par graine 34

B Artefacts sources et reproduction 34

C Note de provenance sur le cache historique 35

1 Réponse courte : qu'est-ce qui a été fait ?

Le résultat CelebA le plus récent est obtenu **sans latent et sans VAE** : la flow map RGB directe conserve une supervision GMD terminale composée $K \in \{1, 2\}$, la contrainte eulérienne E10, puis reçoit pendant seulement 50 updates une supervision GMD locale sur une transition courte. Le point de départ est le meilleur checkpoint E10–5k ; le learning rate est divisé par quatre et vaut 5×10^{-6}. Cette recette et son contrôle apparié sont détaillés en section 11.12. La description latente ci-dessous explique le pipeline historique et la place du VAE ; elle ne doit pas être confondue avec ce résultat RGB actuel.

Le problème initial était d'apprendre à générer des visages CelebA en transportant une loi simple vers la loi des données. Une image RGB de taille 64×64 contient

$$3 \times 64 \times 64 = 12\,288$$

coordonnées. L'estimation KDE du champ de drifting était peu exploitable dans cet espace pixel de grande dimension. La solution testée a été de déplacer le problème dans l'espace latent d'un VAE gelé, suivant la stratégie générale des modèles génératifs latents [2] :

$$3 \times 64 \times 64 \quad \longrightarrow \quad 4 \times 8 \times 8 = 256.$$

La dimension du champ KDE est donc réduite d'un facteur 48.

Dans cet espace de 256 dimensions, une flow map à deux temps

$$\Phi_\theta(x, a, b), \qquad 0 \le a \le b \le 1,$$

est entraînée. Elle doit apprendre trois choses :

1. **la destination** grâce au drifting terminal ;
2. **une direction locale** grâce à deux résidus WGF/KDE ;
3. **la réutilisation de la transition** grâce à une loss de composition.

La configuration minimale retenue est appelée Core C. Une variante ajoute une régularisation eulérienne et est appelée B. L'ancien baseline KDE–WGF latent sert de référence dans cette confirmation. Il ne faut pas le confondre avec GMD, le *Generative Modeling via Drifting* canonique étudié plus loin dans ce rapport.

2 Pipeline complet et place exacte du VAE

2.1 Vue d'ensemble

Préparation des données, effectuée une seule fois

Image CelebA $x \in [0,1]^{3\times64\times64}$
$\downarrow$ recadrage, redimensionnement, passage vers $[-1,1]$
$\downarrow$ encodeur VAE **préentraîné et gelé**
$y = 0.18215\,\mu_{\mathrm{VAE}}(2x-1) \in \mathbb{R}^{4\times8\times8}$
$\downarrow$ cache de latents réels sur disque

Entraînement

$z, \widetilde{z} \sim \mathcal{N}(0, I_{256}) \longrightarrow \Phi_\theta \longrightarrow$ latents générés
$\uparrow$ comparaison KDE/WGF avec les latents réels du cache
Seuls les paramètres θ de la flow map sont optimisés.

Génération après entraînement

$z \sim \mathcal{N}(0, I_{256}) \longrightarrow \Phi_\theta$ composée K fois $\longrightarrow u \in \mathbb{R}^{4\times8\times8}$
$\downarrow$ décodeur VAE **gelé** $\longrightarrow \widehat{x} \in [0,1]^{3\times64\times64}$

Ce schéma montre que le VAE est placé *autour* du problème de transport : son encodeur définit les données latentes et son décodeur transforme les sorties latentes en images. Il n'est pas à l'intérieur de la loss entraînée.

2.2 Le VAE n'a pas été entraîné conjointement

Le codec est le modèle préentraîné `stabilityai/sd-vae-ft-mse` [6], implémenté comme un `AutoencoderKL`. Il possède quatre niveaux de canaux 128/256/512/512, trois canaux RGB en entrée et en sortie, et quatre canaux latents. Sur les images 64×64, sa représentation a la forme $4 \times 8 \times 8$.

Son gel est explicite :

`requires_grad_(False)`, `eval()`.

L'encodage et le décodage sont exécutés sans gradient. Pour l'encodage, on utilise la moyenne de la postérieure, jamais un échantillon aléatoire :

$$E_s(x) = s\,\mu_{\mathrm{VAE}}(2x-1), \qquad s = 0.18215. \tag{1}$$

Pour le décodage :

$$D_s(u) = \mathrm{clip}_{[0,1]}\left(\frac{D_{\mathrm{VAE}}(u/s)+1}{2}\right). \tag{2}$$

Il n'y a donc pendant l'entraînement de la flow map :
- ni loss de reconstruction du VAE ;
- ni terme KL du VAE ;
- ni fine-tuning de l'encodeur ou du décodeur ;
- ni rétropropagation depuis les pixels.

2.3 Données et séparation utilisée

Le cache contient 30,000 images CelebA [5] encodées en `float32`. Les indices $[5000, 30000)$, soit 25,000 images, sont utilisés pour l'entraînement. Les indices $[0, 5000)$ fournissent l'ensemble de

développement destiné au FID. Un audit a détecté que l'indice d'évaluation 652 est identique octet par octet à l'indice d'entraînement 20,010 ; cet élément est retiré. L'évaluation canonique contient donc 4,999 images réelles et 4,999 images générées.

Cet ensemble est disjoint de l'entraînement après le retrait du doublon, mais il a aussi servi à choisir l'objectif, la bandwidth et le nombre d'appels. Il doit donc être décrit comme un **ensemble de développement**, et non comme un test final jamais consulté.

Un second audit exhaustif a ensuite retrouvé les 30,000 PNG exactement dans les 202,599 images CelebA officielles après crop $(0, 20, 178, 198)$ et resize bilinéaire vers 64×64. Il a aussi montré que le paquet historique mélange les partitions officielles. Le slice d'entraînement local contient 19,994 images train, 2,466 validation, 2,530 test, plus dix contenus ambigus dus à des duplications après resize. La référence propre contient 3,995/462/542 images train/validation/test. La séparation locale exclut donc la copie PNG exacte, mais n'est pas le benchmark officiel.

Les vrais splits sont maintenant matérialisés séparément dans `data/celeba64_official_bilinear`, avec exactement 162,770/19,867/19,962 images train/validation/test. Le manifeste a pour SHA-256 `27c3098d04ed8e147f9e7643798ad67d542190495a7c1969701b23a9d5048482`. Ces partitions suivent exactement le fichier de partition CelebA, mais elles ne sont pas parfaitement disjointes au niveau du contenu après crop et resize : le manifeste contient 37 hashes PNG présents dans deux partitions, soit 24 paires train–validation, 11 train–test et 2 validation–test (74 enregistrements au total). Il s'agit d'une propriété du benchmark matérialisé, pas d'un mélange introduit par le loader. Les résultats principaux conservent donc les partitions officielles pour rester comparables ; une éventuelle évaluation dédupliquée devra être étiquetée comme analyse secondaire. Aucun résultat FID de ce rapport ne provient du répertoire test officiel, qui reste exclu de la nouvelle voie officielle. Il ne constitue cependant plus un test globalement vierge pour ce programme de recherche : le paquet local historique contenait déjà 2,530 contenus mappés au test dans son train et 542 dans sa référence dev. La validation officielle a en revanche été ouverte une première fois, au checkpoint GMD 25k préenregistré, après le pré-entraînement MAE et le premier segment du générateur sur le train officiel décrits ci-dessous.

Une voie fail-closed est prête dans `celeba_pixel_gmd_mae_official_train.py`. Elle impose ce train, rehache les 162,770 PNG avant et après préchargement et fixe 192 époques dans `CELEBA_PIXEL_GMD_MAE_OFFICIAL_SPLIT_PROTOCOL.md`. Ses 25 tests CPU sont verts. Le MAE a atteint exactement l'update 121,920 (192 époques) en deux jobs terminés correctement, de 2 h 46 min 15 s et 2 h 52 min 47 s, soit 5 h 39 min 02 s de calcul alloué. Le checkpoint EMA final a pour SHA-256 `9d088740c9cf725809a3d80b124591dc2f229d3c7772b177257320e84bb7d985`.

La voie aval est elle aussi verrouillée dans `celeba_pixel_gmd_generator_official_train.py` et `CELEBA_PIXEL_GMD_GENERATOR_OFFICIAL_SPLIT_PROTOCOL.md`. Elle exige le checkpoint EMA exact du MAE à l'update 121,920, segmente le générateur RGB en 25k/50k/75k/100k, sélectionne uniquement sur les 19,867 images de validation et interdit à cette voie l'accès au répertoire des 19,962 images test. Les 56 tests dédiés et de non-régression passent. Le premier segment 0–25k, job `758904`, est terminé `COMPLETED/0:0`, sans redémarrage : 4 h 12 min 41 s dans le trainer et 4 h 22 min 20 s de walltime Slurm sur huit MI210. Le checkpoint de reprise périodique 25k a pour SHA-256 `64c9c324c80b6ec437590f95bd88f9a043bc40b6799c29c95ddbf4e53ed64868`. Le postflight d'entraînement atteste explicitement que ce segment lui-même n'a calculé aucun FID et n'a lu ni validation ni test. Une cascade d'évaluation séparée, auditée et aveugle jusqu'à l'agrégat, a ensuite ouvert uniquement la validation à 25k ; ses résultats sont rapportés plus loin. Le test officiel reste non lu par cette voie, sans être qualifié de holdout historiquement vierge. Après le rejet fail-closed d'une première tentative de reprise avant tout update scientifique, la continuation propre 25k–50k s'est terminée sous le job `759654`, exactement liée au checkpoint périodique 25k : `COMPLETED/0:0`, sans redémarrage, 4 h 12 min 07 s dans le trainer et 4 h 23 min 25 s de walltime Slurm sur huit MI210. Le checkpoint périodique 50k a pour SHA-256 `f73cf799f4cae7d0f855cf83d9a2fd1b5197092092366b96733615d833e211b3` et le checkpoint final

`dd1fe0ddfd3048abd8fdc9b280253793930a8725b2713855930315308d59c070`. Le postflight est `PASS`, sans FID ni lecture du test. L'évaluation séparée du checkpoint 50k est désormais terminée : sa voie distribuée, calibrée contre les features brutes canoniques, donne les FID brut et EMA rapportés dans la section de protocole commun ci-dessous. Elle n'a pas lu le split test.

3 Structure de la flow map

3.1 Réseau

La flow map latente est un petit U-Net conditionné par les deux temps a, b. La configuration finale contient 1,332,036 paramètres :

Étape	Opération
1	latent $4 \times 8 \times 8$, convolution $4 \to 64$
2	bloc résiduel conditionné, résolution 8×8
3	downsampling $64 \to 128$, résolution 4×4
4	deux blocs résiduels conditionnés à 128 canaux
5	upsampling $128 \to 64$, retour à 8×8
6	connexion skip avec la première branche
7	convolution de sortie $64 \to 4$

Les embeddings sinusoïdaux de a et b, ainsi que le coefficient d'interpolation, conditionnent les blocs résiduels.

3.2 Paramétrisation qui impose l'identité

Pour $a < 1$, on définit

$$\alpha(a,b) = \frac{b-a}{1-a}, \qquad \Phi_\theta(x,a,b) = (1-\alpha(a,b))x + \alpha(a,b)g_\theta(x,a,b). \tag{3}$$

Le cas $a = b = 1$ est défini directement par $\Phi_\theta(x,1,1) = x$. Cette construction garantit exactement

$$\Phi_\theta(x,a,a) = x.$$

Elle garantit également que le coefficient explicite du point de départ s'annule à l'arrivée $b = 1$. Elle ne garantit pas à elle seule que deux transitions composées soient correctes : cette propriété est encouragée par la loss de composition.

3.3 NFE à l'inférence

Le nombre NFE $= K$ est le nombre d'appels au réseau. Par exemple :

$$z \xrightarrow{0\to1/4} x_{1/4} \xrightarrow{1/4\to1/2} x_{1/2} \xrightarrow{1/2\to3/4} x_{3/4} \xrightarrow{3/4\to1} x_1.$$

Le même checkpoint est utilisé à NFE 1, 4 et 16. Par conséquent, **changer NFE ne change pas le temps d'entraînement** ; cela change uniquement la manière d'utiliser le modèle à l'inférence.

Une NFE plus grande ne constitue pas ici le raffinement garanti d'une ODE fixe. Les transitions sont des conditionnements différents du réseau. Si la composition apprise est imparfaite, plus d'appels peuvent améliorer, conserver ou dégrader les échantillons.

4 Champ de drifting et bandwidth

Pour la vitesse KL–KDE [1], les données latentes $Y = (y_j)$ et une référence générée indépendante $R = (r_j)$ donnent

$$w_j(x; Y, h) = \frac{\exp[-\|x - y_j\|^2/(2h^2)]}{\sum_\ell \exp[-\|x - y_\ell\|^2/(2h^2)]}, \tag{4}$$

$$\widehat{s}_h(x; Y) = \frac{1}{h^2} \sum_j w_j(x; Y, h)(y_j - x), \tag{5}$$

$$\widehat{V}(x; Y, R, h) = \widehat{s}_h(x; Y) - \widehat{s}_h(x; R). \tag{6}$$

La bandwidth est un hyperparamètre **fixe**, non appris :

Configuration	Bandwidth	Géométrie
Flow map latente CORE C et B	$h = 3$	euclidienne brute
Baseline KDE–WGF latent	$h = 4$	euclidienne brute
Écran pixel principal	$h = 10$	euclidienne brute

Elle reste identique pendant toutes les mises à jour et tous les temps intermédiaires. Elle n'est plus utilisée après entraînement lors de la simple génération. La différence $h = 3$ contre $h = 4$ signifie que le baseline latent est une référence réglée séparément, pas une ablation où un seul facteur change.

5 Loss de la méthode CelebA retenue

5.1 1. Endpoint drifting : apprendre la destination

Avec $z, \widetilde{z} \sim \mathcal{N}(0, I_{256})$, on calcule

$$y = \Phi_\theta(z, 0, 1), \qquad \widetilde{y} = \mathrm{sg}[\Phi_\theta(\widetilde{z}, 0, 1)].$$

Une étape de drifting détachée construit la cible

$$y_{\text{cible}} = \mathrm{sg}\Big[y + \eta \widehat{V}(y; Y, \widetilde{y}, h)\Big], \qquad \eta = 1,$$

puis

$$\mathcal{L}_{\text{endpoint}} = \mathbb{E}\,\|y - y_{\text{cible}}\|^2. \tag{7}$$

Ce terme dit directement au réseau où déplacer ses sorties finales. C'est l'ancrage principal de l'apprentissage.

5.2 2. Deux résidus WGF : apprendre une direction

Pour un temps intermédiaire a, l'état atteint est détaché :

$$x_a = \mathrm{sg}[\Phi_\theta(z, 0, a)].$$

Avec $\varepsilon = 0.005$, l'échelle physique $S = 100$ et $\Delta\sigma = S\varepsilon$, les deux vues sont

$$\mathcal{L}^0_{\text{WGF}} = \mathbb{E}\left\| \frac{\Phi_\theta(z, 0, a + \varepsilon) - x_a}{\Delta\sigma} - \widehat{V}(x_a) \right\|^2, \tag{8}$$

$$\mathcal{L}^{\text{local}}_{\text{WGF}} = \mathbb{E}\left\| \frac{\Phi_\theta(x_a, a, a + \varepsilon) - x_a}{\Delta\sigma} - \widehat{V}(x_a) \right\|^2. \tag{9}$$

Les deux termes visent la même vitesse au même état, mais l'un observe le trajet canonique depuis zéro et l'autre une transition locale.

5.3 3. Composition : rendre la transition réutilisable

Pour $a < b$, la loss demande

$$\mathcal{L}_{\text{composition}} = \mathbb{E}\,\|\Phi_\theta(\text{sg}[\Phi_\theta(z,0,a)],a,b) - \text{sg}[\Phi_\theta(z,0,b)]\|^2\,. \tag{10}$$

Le chemin direct $0 \to b$ joue le rôle de cible détachée. La contrainte est apprise sur les états visités ; elle ne certifie pas une propriété de semi-groupe exacte partout dans l'espace latent.

5.4 Somme réellement optimisée : Core C

La loss finale retenue est

$$\boxed{\mathcal{L}_C = 0.025\left(\mathcal{L}^0_{\text{WGF}} + \mathcal{L}^{\text{local}}_{\text{WGF}}\right) + 0.1\mathcal{L}_{\text{composition}} + 5\mathcal{L}_{\text{endpoint}}.} \tag{11}$$

Terme	Poids effectif	Rôle simple
Endpoint	5	Fixer la destination terminale.
WGF origine + local	0.025	Donner une direction intermédiaire approximative.
Composition	0.1	Permettre de réutiliser le même réseau sur plusieurs intervalles.

Les anciennes losses eulérienne, Lagrangienne et d'endpoint depuis un temps arbitraire ne sont pas actives dans Core C. La variante B ajoute seulement

$$\mathcal{L}_B = \mathcal{L}_C + 10\mathcal{L}_{\text{Eulerian}}. \tag{12}$$

5.5 Baseline KDE–WGF historique utilisé comme référence

Le baseline historique utilise le même U-Net latent, mais seulement comme générateur terminal $G_\theta(z) = \Phi_\theta(z,0,1)$. Sa loss est

$$\mathcal{L}_{\text{drift}} = \mathbb{E}\left\|G_\theta(z) - \text{sg}\Big[G_\theta(z) + \widehat{V}(G_\theta(z))\Big]\right\|^2. \tag{13}$$

Il n'apprend ni transitions intermédiaires ni règle de composition. À l'inférence il produit une sortie en un seul appel.

Malgré le nom `drift` employé dans les anciens scripts, cette équation est une différence de scores KDE gaussiens avec une bandwidth brute fixe. Elle n'est pas la loss GMD canonique de Deng et al., qui emploie des features gelées, un noyau laplacien multi-température et une normalisation adaptative. Les deux familles sont désormais nommées séparément dans tous les nouveaux résultats.

6 Comment l'entraînement a été exécuté

6.1 Deux phases, et non un entraînement VAE + flow simultané

Phase A — pré-encodage. Les 30,000 images sont passées une fois dans l'encodeur VAE gelé. Les latents $4 \times 8 \times 8$ sont sauvegardés. Cette phase n'optimise aucun paramètre.

Phase B — entraînement de la flow map. Le trainer recharge uniquement le cache. Le VAE encodeur n'est plus nécessaire dans la boucle. Le décodeur peut être chargé sur le rang zéro pour de petits panneaux diagnostiques, toujours sans gradient.

6.2 Une itération de Core C, pas à pas

À chaque mise à jour :

1. charger un batch de vrais latents Y depuis le cache ;
2. tirer deux batchs indépendants $z, \tilde{z} \sim \mathcal{N}(0, I_{256})$;
3. tirer quatre groupes de temps, identiques sur les huit GPU ;
4. calculer les états du modèle et rassembler les supports KDE globaux ;
5. construire les vitesses KDE et les cibles sous stop-gradient ;
6. calculer les trois termes de l'équation (11) ;
7. les additionner, effectuer **un seul** `backward()`, puis **un seul** pas AdamW sur les paramètres de Φ_θ ;
8. mettre à jour une copie EMA du réseau après le warm-up.

Les trois losses sont donc entraînées ensemble dans chaque itération. En revanche, le VAE, les vitesses KDE, les branches enseignantes et l'EMA ne sont pas optimisés par ce gradient.

6.3 Configuration exacte de la confirmation finale

Table 1 – Hyperparamètres communs aux runs latents confirmatoires.

Élément	Valeur
Données d'entraînement	25,000 latents, indices $[5000, 30000)$
Représentation	$4 \times 8 \times 8 = 256$, sans normalisation par canal
Prior	$\mathcal{N}(0, I_{256})$
Réseau	U-Net latent à deux temps, 1,332,036 paramètres
Mises à jour	5,000
Matériel	un nœud, 8 GPU AMD Instinct MI210, DDP
Batch	128 par GPU, 1,024 global
Optimiseur	AdamW, learning rate 2×10^{-4}
AdamW	betas $(0.9, 0.999)$, weight decay 0
Gradient clipping	norme maximale 1
EMA	decay 0.999, démarrage après 500 mises à jour
KDE flow	KL, géométrie brute, bandwidth fixe $h = 3$
KDE drift	KL, géométrie brute, bandwidth fixe $h = 4$
Supports flow	support global, 4 groupes temporels synchronisés
Support par temps	1,024 latents de données, 256 références modèle
Temps	$\varepsilon = 0.005$, échelle $S = 100$, grille d'inférence uniforme
Drifting terminal	pas $\eta = 1$
Graines d'entraînement	41, 42 et 43
Déterminisme	algorithmes déterministes activés

DDP synchronise les gradients. L'option de support global rassemble en plus les particules détachées des huit rangs pour le KDE. Le batch global améliore donc à la fois le nombre d'exemples vus par l'optimiseur et le nombre de points supportant l'estimateur KDE.

7 Protocole d'évaluation

Tous les résultats principaux utilisent :

— les poids EMA finaux ;
— 4,999 images générées et la même référence réelle de 4,999 images ;
— les mêmes tirages gaussiens indexés entre méthodes comparables ;
— les trois graines d'entraînement 41, 42 et 43 ;
— les NFE communes 1, 4 et 16 pour les flow maps ;
— les features pool3 de dimension 2,048 de `pytorch-fid` 0.3.0 ;
— KID avec 100 sous-échantillonnages de taille 1,000 et graine 0.

FID [3] et KID [4] doivent être minimisés. Tous les signes ± du tableau principal sont les écarts-types échantillonnaux sur les trois graines d'entraînement, et non des erreurs standards.

8 Résultats principaux sur CelebA latent

TABLE 2 – Confirmation CelebA-64 verrouillée par les sources, poids EMA finaux. Moyenne ± écart-type sur trois graines. La trace des vraies images vaut 126.959.

Méthode	NFE	FID↓	KID×10^3 ↓	trace
CORE C	1	61.556 ± 0.590	52.714 ± 0.374	130.603 ± 0.429
CORE C	4	$\mathbf{45.762 \pm 1.513}$	33.716 ± 1.306	114.241 ± 2.271
CORE C	16	46.101 ± 0.685	33.143 ± 0.807	106.018 ± 3.613
B, avec Eulerian	1	65.205 ± 0.872	57.601 ± 1.102	136.614 ± 1.106
B, avec Eulerian	4	45.906 ± 2.293	34.691 ± 2.142	119.408 ± 5.080
B, avec Eulerian	16	47.253 ± 1.759	36.542 ± 2.365	117.054 ± 4.757
KDE–WGF latent historique	1	66.020 ± 1.002	56.241 ± 1.383	129.398 ± 0.921

8.1 Lecture directe du tableau

1. À budget d'inférence identique d'un appel, CORE C améliore le FID du KDE–WGF sur les trois graines. Le contraste apparié dérivé des cellules validées vaut -4.464 ± 0.427, soit 6.76% de FID en moins numériquement.
2. Le passage de NFE 1 à NFE 4 pour le *même modèle* CORE C apporte l'amélioration principale : -15.793 ± 0.927 points de FID.
3. Le passage de NFE 4 à NFE 16 donne $+0.338 \pm 0.838$. Il n'y a donc plus d'amélioration moyenne du FID.
4. À NFE 4, la différence descriptive entre les moyennes de CORE C et du KDE–WGF est de -20.257 points, soit 30.68% de moins. Cette comparaison utilise toutefois quatre appels contre un.
5. La variante eulérienne B ne démontre pas d'avantage : à NFE 4, $B - C = +0.144 \pm 3.805$. Avec seulement trois graines, cette différence est non résolue ; CORE C reste plus simple, plus rapide et légèrement meilleur en moyenne.

Le FID presque identique entre NFE 4 et NFE 16 ne signifie pas que tous les aspects sont constants. La trace des features décroît de 114.241 à 106.018, contre 126.959 pour les vraies images : davantage de compositions contractent la diversité mesurée. NFE 4 est donc le compromis empirique retenu.



FIGURE 1 – Grille qualitative fixe pour la graine 42. Les colonnes générées utilisent les mêmes tirages latents selon les méthodes. La première ligne réelle est une référence non appariée. Aucune image n'a été sélectionnée selon sa qualité. Les visages deviennent plus structurés entre NFE 1 et NFE 4, mais des déformations, fusions et couleurs artificielles restent visibles.

8.2 Résultats qualitatifs

9 Temps d'entraînement mesurés

9.1 Deux mesures différentes

Deux chronomètres sont disponibles et ne doivent pas être mélangés :

Temps interne du trainer. Il commence juste avant la boucle des 5,000 mises à jour. Il inclut les checkpoints tous les 1,000 pas, les petits diagnostics périodiques et les sauvegardes/générations finales. Il exclut le chargement initial du cache et du modèle, ainsi que la préparation de la provenance avant la boucle.

Temps mur Slurm. Il mesure le job complet, depuis le démarrage jusqu'à la fin. Il comprend donc l'initialisation Python/ROCm, les chargements et les opérations de fin de job. Il n'inclut pas le temps passé en file d'attente.

TABLE 3 – Temps par graine sur un nœud de huit MI210. Les graines sont données dans l'ordre 41, 42, 43.

Méthode	Temps trainer par graine (s)	Moyenne trainer (s)	Temps Slurm par graine (s)	Moyenne Slurm (s)
CORE C	322.670 ; 334.138 ; 327.096	327.968 ± 5.783	476 ; 488 ; 480	481.333 ± 6.110
B, avec Eulerian	355.890 ; 371.655 ; 385.411	370.985 ± 14.772	494 ; 524 ; 542	520.000 ± 24.249
KDE–WGF latent	189.511 ; 172.443 ; 178.823	180.259 ± 8.624	353 ; 325 ; 331	336.333 ± 14.742

TABLE 4 – Lecture pratique des temps moyens.

Méthode	Trainer	Job complet	Coût trainer relatif au drift
CORE C	5 min 28 s	8 min 01 s	1.82×
B, avec Eulerian	6 min 11 s	8 min 40 s	2.06×
KDE–WGF latent	3 min 00 s	5 min 36 s	1.00×

La flow map coûte plus cher à entraîner parce qu'une itération contient plusieurs appels pour les états intermédiaires, les transitions locales et la composition. La variante B ajoute encore une branche eulérienne et prend en moyenne 13.1% de temps interne de plus que CORE C.

Préparation VAE séparée. La construction initiale du cache de 30,000 latents a pris environ 39 secondes dans la barre de progression de l'encodeur, et 197 secondes de temps mur Slurm sur un seul MI210. C'est un coût ponctuel d'encodage, pas un entraînement du VAE.

Génération séparée. Pour CORE C, générer, décoder et écrire 4,999 PNG sur un MI210 prend 46.70 ± 0.65, 46.79 ± 0.62 et 48.03 ± 1.11 secondes à NFE 1, 4 et 16. Ces mesures incluent le décodeur VAE et les écritures disque ; elles ne constituent donc pas un benchmark pur du réseau. Le temps du calcul FID seul n'a pas été enregistré et n'est pas inventé ici.

10 Pourquoi le latent était nécessaire dans le pipeline testé

10.1 Contrôles du codec et du prior

Ces contrôles disent plusieurs choses différentes :

— le VAE conserve une grande partie de l'information des visages, mais sa reconstruction n'est pas une borne mathématique sur le FID du générateur ;

TABLE 5 – Références contextuelles. Ce sont des contrôles fixes ou des runs uniques, pas des moyennes à trois graines comparables au tableau 2.

Référence ou contrôle	FID↓	KID×10^3 ↓	trace
Réel–réel, deux moitiés disjointes	10.996	0.133	127.112
Reconstruction par le VAE	15.814	10.822	125.172
Décodage de $z \sim \mathcal{N}(0, I)$	352.095	455.074	117.792
Gaussienne ajustée par canal	324.620	399.839	140.473
Gaussienne diagonale, 256 coordonnées	282.499	341.550	157.866
Gaussienne à covariance pleine	79.481	72.512	147.396
Meilleur écran pixel, une graine	177.979	199.277	111.260

— un prior normal standard décodé directement ne correspond pas à la loi des latents CelebA ;
— la covariance pleine explique une partie importante de l'écart, sans capturer toute la structure ;
— la flow map à NFE 4 descend nettement sous la Gaussienne pleine.

10.2 Comparaison historique directement dans les pixels

TABLE 6 – Écran CelebA pixel sans VAE. Ces cellules ne forment pas une ablation parfaitement appariée.

Méthode pixel	Checkpoint/poids	NFE	FID↓
KDE–WGF historique	final, pas 2,000, brut	1	177.979
KDE–WGF historique	final, pas 2,000, EMA	1	201.014
Flow map KL $h = 10$	pas 1,000, EMA	1	360.951
Flow map KL $h = 10$	pas 1,000, EMA	4	352.187

Pour le run complet de 2,000 mises à jour, le temps interne vaut 715.976 s (11 min 56 s) pour la flow map pixel et 180.636 s (3 min 01 s) pour le KDE–WGF pixel, sur huit MI210 avec batch local 16 et batch global 128.

Cette comparaison doit rester historique et diagnostique : elle ne contient qu'une graine, le FID de la flow map disponible vient du checkpoint 1,000 alors que celui du KDE–WGF vient du pas 2,000, les poids comparés ne sont pas du même type, et l'objectif pixel est l'ancienne version transférée depuis MNIST, pas une transposition exacte de CORE C. Elle montre que **la flow map pixel testée n'a pas résolu le problème**, pas que toute flow map en pixels est impossible.

Les diagnostics expliquent l'échec observé. Pour la flow pixel $h = 10$, les ESS attraction/répulsion sont 18.46/23.35, les cosinus de vitesse environ 0.21 et les résidus relatifs 4.10/4.92. La trace de covariance des features tombe à 40.33 à NFE 4, contre 111.26 pour le KDE–WGF pixel brut et 126.96 pour les vraies images. Le champ KDE pixel et la diversité sont donc très faibles.

10.3 Interprétation prudente

Le passage de 12,288 pixels à 256 latents rend les distances KDE beaucoup plus exploitables et délègue la reconstruction locale au décodeur gelé. Mais la comparaison pixel/latent change aussi l'architecture, le batch global, le nombre de mises à jour et l'objectif. Les résultats démontrent que le **pipeline latent testé** fonctionne mieux ; ils n'isolent pas causalement la réduction de dimension comme unique explication.

11 Mise à jour : le GMD canonique sur les images

11.1 Que signifie GMD ?

GMD signifie *Generative Modeling via Drifting* [7]. C'est une méthode d'entraînement, tandis que le FID est seulement une métrique d'évaluation. Pour chaque famille de features gelées f_ℓ, GMD construit une cible détachée qui attire les features générées vers celles des vraies images et tient compte des autres échantillons générés. Son noyau pratique est laplacien,

$$K_\tau(u, v) = \exp\left(-\frac{\|u - v\|_2}{\tau}\right), \qquad \tau \in \{0.02, 0.05, 0.2\},$$

avec normalisations softmax ligne/colonne et normalisation RMS de la force. Les températures nominales sont fixes, mais les distances de chaque famille sont divisées par une échelle estimée sur le batch : la bandwidth effective dans les coordonnées brutes est donc adaptative.

Le MAE ou ConvNeXt utilisé par GMD est gelé : ses poids ne sont pas optimisés. Le gradient doit néanmoins traverser ses opérations depuis les features de l'image générée jusqu'au générateur. Cette représentation perceptuelle est la différence centrale avec l'ancien KDE–WGF isotrope des équations (6)–(13).

11.2 Ce que la littérature établit réellement

Le papier GMD original ne publie pas de résultat CelebA. Sur ImageNet-256, les auteurs indiquent ne pas avoir réussi sans encodeur de features, même avec un VAE latent. Leur ablation passe notamment de FID 8.46 avec un MAE largeur 256 préentraîné 192 époques à 4.28 avec un MAE largeur 640 préentraîné 1,280 époques, puis 3.36 après fine-tuning de classification. Cela ne prouve pas que le VAE est obligatoire : leur meilleure recette RGB directe fonctionne aussi, mais avec des features MAE et ConvNeXt-V2 beaucoup plus fortes.

La recette ImageNet forte utilise un DiT, AdamW avec $\beta = (0.9, 0.95)$, clipping à 2, warmup de 10k et un seul appel réseau à l'inférence. La branche latente est entraînée 200k updates ; la branche RGB directe, 100k updates. Dans cette dernière, 128 classes et 64 générations par classe donnent 8,192 sorties par update, avec 128 positifs et 64 négatifs par champ conditionnel. Les FID-50k ImageNet publiés sont :

Recette GMD ImageNet-256	DiT-B	DiT-L
VAE latent	1.75	**1.54**
RGB direct, MAE + ConvNeXt-V2	1.76	**1.61**

Ces scores ne sont pas des baselines CelebA. Ils donnent en revanche deux enseignements transférables : le VAE est optionnel, et l'espace de features gelé est une partie essentielle de la méthode. L'ablation RGB du papier passe de 32.11 avec le MAE faible à 9.35 avec le MAE fort, puis 3.70 après ajout de ConvNeXt-V2 ; prolonger ensuite l'entraînement donne 2.19 à 320 ńépoquesż et 1.76 à 640. De même, supprimer la répulsion produit un FID de 177.14. Une interprétation de CelebA qui ne regarde que le VAE ou le nombre d'updates manquerait donc deux variables causales majeures : les features et l'antisymétrie attraction–répulsion.

Le travail Long–Short ultérieur [8] teste explicitement CelebA-HQ avec VAE Stable Diffusion, DiT-B/2, MAE latent gelé préentraîné 250k updates et plusieurs milliers de groupes de features. À 100k updates, son FID vaut 28.12, 18.87 et 14.71 pour des batchs respectifs de 64, 256 et 1,024 ; à batch 64 et 400k updates avec baisse du learning rate, il atteint 19.36. Ces valeurs ne sont pas comparables numériquement à nos FID CelebA-64 locaux, mais elles réfutent l'idée d'un échec intrinsèque du drifting sur les visages.

11.3 Résultats GMD locaux déjà mesurés

TABLE 7 – GMD local sur le holdout de développement de 4,999 images. Toutes les lignes sont mono-graine et ne sont pas des scores test officiels.

Configuration	Espace/features	Updates	FID↓
Pyramide brute	latent, sans feature apprise	10k	77.875
MAE pilote gelé	latent VAE	5k	56.251
GMD principal	latent VAE, MAE 20k	30k	**37.413**
GMD direct RGB	sans VAE, MAE pixel 10k	10k	53.262
GMD direct RGB + ConvNeXt	sans VAE, MAE + ConvNeXt-V2 Base	10k	**18.887**

Le résultat RGB direct est important : il montre que le VAE n'est pas une condition mathématique nécessaire. À 10k updates, cette expérience reste très précoce face aux 100k du papier et son MAE largeur 64 est très inférieur au MAE largeur 640 de la recette forte. Le résultat ne permet donc ni de conclure à un échec, ni de comparer 53.262 au FID ImageNet publié. Dans la configuration locale observée, le générateur GMD RGB coûte 614.232 ms/update sur huit MI210, contre une médiane de 34.489 ms/update pour le petit KDE–WGF latent ; ce ratio inclut le DiT-B, les pixels et l'encodeur de features, et n'est pas le surcoût isolé de la formule GMD.

La comparaison directement utile avec la flow map LSD principale donne le sens opposé à l'intuition ń ma méthode est forcément plus lente ż. Sur le même type de nœud à huit MI210, les segments observés de cette flow map prennent environ 176–183 ms/update, contre environ 607 ms/update pour le premier segment GMD RGB officiel : dans ces implémentations, la flow map est donc approximativement 3.3–3.5× plus rapide par update. Ce n'est pas une comparaison isolée des losses : la flow map a environ 21 millions de paramètres et travaille en latent, tandis que le GMD utilise un DiT-B d'environ 132 millions de paramètres, les pixels RGB et un MAE gelé. De plus, une update flow map consomme 256 latents réels contre 128 positifs réels insérés par l'update GMD. Les tableaux finaux devront donc rapporter à la fois le nombre d'updates, le temps mur et l'exposition cumulée aux données.

11.4 Validation officielle du GMD RGB à 25k

Le checkpoint périodique 25k du run entraîné exclusivement sur les 162,770 images du train officiel a été évalué une seule fois sur les 19,867 images de validation. Les poids bruts et EMA utilisent exactement les mêmes graines, 19,867 générations, NFE 1 et le seed 42,001. Les métriques sont restées scellées jusqu'au succès conjoint des jobs raw `759656`, EMA `759657` et agrégat `759658`. Les trois jobs sont `COMPLETED/0:0`, sans redémarrage, avec des walltimes respectifs de 8 min 40 s, 9 min 48 s et 6 min 28 s ; un audit indépendant a reconstruit le rapport final byte-for-byte et confirmé `test_read=false`.

Poids	FID↓	KID↓	IC 95% KID	trace générée
Bruts	45.716209	0.0409812	[0.0408361, 0.0411263]	114.248
EMA	**37.942950**	**0.0343718**	[0.0342019, 0.0345416]	109.739

L'EMA abaisse le FID de 7.773 points, soit 17.00%, et le KID de 0.006609, soit 16.13%. Les intervalles KID ne se recouvrent pas. Une grille déterministe répartie sur toute la séquence montre des visages reconnaissables et variés, sans effondrement global, mais encore de nombreux artefacts de haute fréquence, quadrillages colorés et fonds déformés. Ce profil est cohérent avec un modèle qui a appris la structure globale de CelebA mais dont la fidélité fine reste insuffisante.

Ce résultat est un diagnostic mono-graine à un checkpoint préenregistré, pas une sélection finale. Il ne faut surtout pas le soustraire directement aux FID de la flow map mesurés sur l'ancien holdout de développement de 4,999 images : le split réel, le nombre d'échantillons et le nombre d'updates diffèrent. La comparaison numérique honnête exige de réévaluer les deux méthodes dans la même cellule officielle. Le rapport final GMD a pour SHA-256 `9adeb346a05ee0e9e0cfc293e3931ce92c1d2fe04c7ba4202097cb9b9a158a93`.

11.5 Recette Flow Maps publiée sur CelebA-64

Contrairement à GMD, le travail Flow Maps de Boffi, Albergo et Vanden-Eijnden publie bien une expérience CelebA-64 [9]. Il ne publie toutefois aucune comparaison GMD–Flow Maps sur CelebA et aucune recette ImageNet. Le baseline externe pertinent est donc uniquement la ligne LSD CelebA-64 du papier.

La méthode apprend directement dans l'espace RGB, sans VAE. Avec x_0 gaussien indépendant et x_1 réel normalisé dans $[-1, 1]$, elle emploie l'interpolant linéaire et la paramétrisation

$$I_t = (1-t)x_0 + tx_1, \qquad X_{s,t}(x) = x + (t-s)v_{s,t}(x).$$

Sur 75% du batch, la diagonale $s = t$, avec $t \sim \mathcal{U}[0, 1]$, apprend le champ instantané par flow matching vers $x_1 - x_0$. Sur les 25% restants, deux uniformes sont triées pour échantillonner (s, t) uniformément sur le triangle $0 \le s < t \le 1$. La loss LSD aligne le JVP temporel $\partial_t X_{s,t}(I_s)$ sur le champ diagonal $v_{t,t}(X_{s,t}(I_s))$, ce dernier servant de cible avec stop-gradient. L'enseignant est donc le réseau courant détaché, pas une EMA. Une tête $w(s, t)$ apprend la pondération hétéroscédastique $\exp(-w)\|r\|^2 + w$.

Élément	Recette CelebA-64 publiée
Représentation	RGB $3 \times 64 \times 64$, aucun VAE, aucun latent ; normalisation $[-1, 1]$, base gaussienne à variance adaptée.
Réseau	EDM2 configuration G, base 128, multiplicateurs $[1, 2, 3, 4]$, trois blocs résiduels par résolution, attention en 16×16 et 8×8, dropout nul ; embeddings de s et $t - s$, conditionnement FiLM.
Optimisation	RAdam par défaut, clipping global 1 ; LR 10^{-2} constant jusqu'à 35k puis $10^{-2}/\sqrt{k/35000}$. Pas de préentraînement ni d'annealing temporel.
Budget papier	Batch global 256, 800k updates, soit 204.8 millions d'images vues ; 75% flow matching et 25% LSD.
EMA et inférence	EMA 0.9999 pour le résultat final ; composition sur une grille temporelle uniforme, NFE $\in \{1, 2, 4, 8, 16\}$.
Évaluation	FID-10k tous les 10k updates, puis FID-50k post-hoc ; meilleur checkpoint sélectionné *séparément pour chaque NFE* sur toute la trajectoire.

Le papier rapporte les valeurs suivantes, toutes avec EMA 0.9999 et 50,000 images générées :

Flow Maps LSD, CelebA-64	NFE 1	NFE 2	NFE 4	NFE 8	NFE 16
FID-50k publié	12.22	5.74	3.18	2.18	**1.96**

Correction importante : suffixe de checkpoint. Dans le code auteur figé au commit `2f115a0`, `save_freq=5000` et le nom sauvegardé contient `step // save_freq`. Par conséquent, le suffixe n'est pas le nombre d'updates :

`_k.pkl` $\iff$ update $5{,}000\,k$.

Ainsi `_1.pkl`=5k, `_2.pkl`=10k et, avec le budget du papier, `_160.pkl`=800k. Le FID online n'étant calculé que tous les 10k, les checkpoints observés par cette sélection sont les 80 suffixes pairs `_2,_4,...,_160`. Les auteurs ne publient pas les suffixes gagnants par NFE : aucun checkpoint local précoce ne doit être appelé ń checkpoint officiel gagnant ż. La config fournie dans le dépôt emploie batch 512 et 400k updates, donc termine à `_80.pkl` ; elle conserve 204.8 millions d'exemples mais n'est pas la même trajectoire d'optimisation que la recette batch 256/800k écrite dans le papier.

11.5.1 Défaut de layout multi-GPU dans la release

L'audit du code auteur met en évidence une interaction de sharding. Les temps sont construits globalement sous la forme [toute la diagonale, tout le triangle], puis découpés en blocs contigus par GPU. Or la loss reclasse ensuite les premiers 75% de *chaque shard* en flow matching et les derniers 25% en LSD. Avec huit GPU et un batch global de 256, la répartition effective est :

Temps effectivement fourni	Branche appliquée	Fraction	Lecture
diagonale	flow matching	56.25%	utile
diagonale	LSD	18.75%	$s = t$, signal LSD essentiellement perdu
triangle	flow matching	18.75%	FM encore valide, s est ignoré
triangle	LSD	6.25%	utile

La part totale adressée à FM reste donc 75%, mais seulement 6.25% du batch porte le signal LSD hors diagonale attendu, au lieu de 25%. Le layout local `release` reproduit ce comportement ; le layout `stratifié` permute les tuples avant le sharding afin que chaque GPU reçoive bien 75/25. Cette correction correspond à l'algorithme du papier, sans être identique octet par octet à la release. Le commit public ne permet pas de savoir quel layout exact a produit les FID publiés : les deux bras doivent donc être conservés, l'un comme contrôle de release et l'autre comme test de l'intention mathématique.

11.6 Comparaison finale dans un protocole commun direct-RGB

Cette expérience répond à la comparaison qui manquait ci-dessus. Les deux familles sont évaluées sur les **19,867 images de la validation officielle CelebA-64**, avec l'InceptionV3 `pytorch-fid` pool3 de dimension 2,048. Le calcul utilise des batches de 128, huit workers et un cache de features vérifié par SHA-256. Pour les cellules Flow Maps, le KID est la moyenne de 100 sous-échantillonnages de taille 1,000, avec graine métrique 0. Les images générées sont RGB 64×64 : **aucun VAE et aucun espace latent ne sont utilisés** dans cette comparaison.

Le drifting/GMD officiel est mesuré à l'update 50,000 et à NFE 1. Son contrôle brut distribué reproduit le calcul canonique à 1.09×10^{-5} FID près, bien sous la tolérance préenregistrée 10^{-3}. Il donne :

Méthode/poids	Checkpoint	FID↓
Drifting/GMD direct-RGB, brut	50k	40.095945
Drifting/GMD direct-RGB, EMA	50k	**35.230066**

La matrice Flow Maps contient exactement 20 configurations : deux layouts (release et stratifié), deux jeux de poids (bruts et EMA 0.9999), puis NFE $\in \{1, 2, 4, 8, 16\}$. Toutes utilisent le même checkpoint 25k et la graine de génération 42,001. Les valeurs suivantes proviennent des reçus finaux, sans sélection d'image :

Layout	Poids	NFE	FID↓	KID↓
release	brut	1	**423.422679**	**0.580899231**
release	brut	2	423.422681	0.580899236
release	brut	4	423.422680	0.580899234
release	brut	8	423.422680	0.580899234
release	brut	16	423.422680	0.580899234
release	EMA 0.9999	1	**429.428267**	**0.588614773**
release	EMA 0.9999	2	433.984787	0.597939774
release	EMA 0.9999	4	436.248876	0.602835295
release	EMA 0.9999	8	437.305765	0.605148560
release	EMA 0.9999	16	437.792337	0.606228803
stratifié	brut	1	374.801540	**0.500694627**
stratifié	brut	2	**374.801540**	0.500694628
stratifié	brut	4	374.801540	0.500694628
stratifié	brut	8	374.801540	0.500694628
stratifié	brut	16	374.801540	0.500694628
stratifié	EMA 0.9999	1	441.778477	0.614632723
stratifié	EMA 0.9999	2	441.547976	0.614113183
stratifié	EMA 0.9999	4	441.396701	0.613777088
stratifié	EMA 0.9999	8	441.345398	0.613666404
stratifié	EMA 0.9999	16	**441.316122**	**0.613603602**

Le meilleur Flow Maps est donc le layout stratifié brut, NFE 2 si l'on trie strictement par FID : **374.801540**, avec KID 0.500694628. Le minimum KID appartient à NFE 1 (**0.500694627**), pas à NFE 2 ; l'écart de 1.74×10^{-9} est toutefois numériquement négligeable. À l'arrondi affiché, les cinq cellules brutes stratifiées sont identiques. Plus précisément, leur amplitude n'est que 1.57×10^{-7} FID ; celle des cinq cellules release brutes est 2.30×10^{-6}. Cela montre que, pour les poids bruts de ce checkpoint, composer la carte davantage ne corrige pas la distribution. Le layout stratifié améliore le meilleur brut release de 48.621139 points de FID, mais l'EMA est moins bonne que les poids bruts dans les deux layouts. Le meilleur FID Flow reste 339.571474 points au-dessus du GMD EMA 50k.

Interprétation correcte. Cette différence démontre qu'au stade évalué, la recette Flow Maps direct-RGB apprend beaucoup moins bien CelebA que le drifting/GMD direct-RGB. Elle ne démontre pas à elle seule une supériorité intrinsèque de la loss GMD : GMD est évalué à 50k, Flow Maps à 25k, les architectures et objectifs diffèrent, et la comparaison n'est normalisée ni par nombre d'updates, ni par exemples vus, ni par FLOP ou GPU-heures d'entraînement. Le checkpoint Flow ne représente en outre que 3.125% du budget planifié de 800k updates.

11.7 Ne pas confondre les deux protocoles FID déjà exécutés

Deux évaluateurs locaux répondent à deux questions différentes. Leurs nombres ne doivent jamais être placés dans la même colonne :

	Protocole commun local	Protocole aligné sur le papier Flow Maps
Question	Comparer localement GMD et Flow Maps avec une référence identique	Comparer une Flow Maps locale à l'échelle FID publiée
Réels	validation CelebA, 19,867 images, crop 178 puis bilinéaire 64	TFDS `train`, 162,770 images, crop centré 140 puis resize area 64
Extracteur	`pytorch-fid`, pool3	InceptionV3 JAX compatible release
Générations	19,867, poids brut ou EMA selon la cellule	50,000, EMA 0.9999, seed 42
Mesures	FID et KID	FID, NFE $\{1, 2, 4, 8, 16\}$
Usage autorisé	Comparaison interne à preprocessing et référence communs	Diagnostic de réplication Flow Maps ; pas comparaison numérique au GMD commun

Le second protocole a déjà été exécuté, et pas seulement spécifié. Les stats réelles train ont pour SHA-256 `d33ba2dd81902b223148d3213c0029e027e23bd1f3c475ae4822b26166b8db0a`. Chaque checkpoint ci-dessous a été évalué avec 50,000 générations, EMA 0.9999 et les cinq NFE ; le tableau donne son minimum parmi ces cinq cellules :

Layout	Update	Meilleur FID (NFE)	Layout	Update	Meilleur FID (NFE)
release	5k	412.6473 (16)	stratifié	5k	439.6255 (1)
release	10k	446.1148 (2)	stratifié	10k	445.4943 (16)
release	15k	436.8229 (2)	stratifié	15k	440.4573 (1)
release	20k	**407.5792 (2)**	stratifié	20k	446.2518 (1)
release	25k	431.0651 (1)	stratifié	25k	**443.8792 (16)**
release	30k	442.1410 (1)			
release	35k	446.0737 (1)			

Ces FID autour de 408–446 confirment que l'écart énorme ne vient pas seulement du choix PyTorch-FID/validation du protocole commun. Ils ne sont cependant **pas** des résultats finaux de réplication : ce sont des checkpoints à 3.1–4.4% du budget, le papier sélectionne séparément chaque NFE sur toute la trajectoire jusqu'à 800k, et les suffixes gagnants publiés sont inconnus.

11.8 Trajectoire des checkpoints Flow Maps, de 5k à 35k

Pour déterminer si le mauvais FID à 25k venait simplement d'un entraînement trop court, 20 nouvelles cellules ont été évaluées à NFE 1 et réunies aux quatre ancres 25k du protocole commun. Le jeu final contient donc exactement 24 mesures authentifiées : deux layouts, poids bruts ou EMA 0.9999, entre 5k et 35k selon les checkpoints réellement disponibles. Le split, l'extracteur, les graines et tous les paramètres FID/KID restent inchangés.

Série	Meilleur FID (checkpoint)	Meilleur KID (checkpoint)
release, brut	374.010005 (15k)	0.491099095 (15k)
release, EMA 0.9999	409.774695 (20k)	0.551592170 (20k)
stratifié, brut	**336.106247 (5k)**	**0.430355872 (5k)**
stratifié, EMA 0.9999	436.766160 (15k)	0.607057506 (5k)

Le meilleur point global est stratifié/brut à 5k. Pour release/brut, le FID baisse de 445.480410 à 374.010005 entre 5k et 15k, puis remonte à 423.422679 à 25k. Pour stratifié/brut, le checkpoint

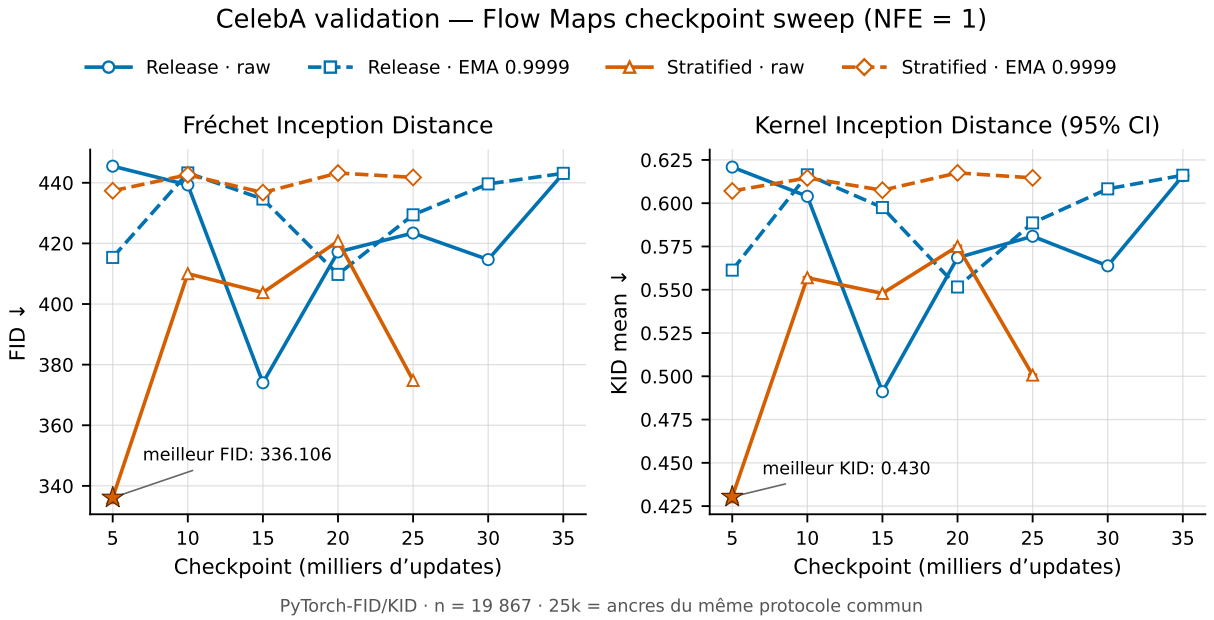


FIGURE 2 – FID et KID PyTorch sur les 19,867 images de validation CelebA, pour les layouts release et stratifié avec poids bruts ou EMA 0.9999 (NFE 1). Aucun point interpolé n'est ajouté ; les segments servent seulement de guides visuels. Les quatre points 25k sont les ancres du protocole commun.

25k est moins bon que 5k de 38.695293 points de FID et de 0.070339 en KID. Le classement des deux layouts s'inverse aussi selon le checkpoint : stratifié/brut gagne à 5k, 10k et 25k, mais perd à 15k et 20k. Enfin, l'EMA 0.9999 dégrade les cinq checkpoints stratifiés communs de 22.465372 à 101.257278 points de FID par rapport au brut.

Ces observations montrent seulement qu'une extrapolation monotone depuis la fenêtre 5k–35k serait injustifiée : davantage d'updates n'améliore pas chaque checkpoint précoce. Elles ne réfutent nullement le sous-entraînement. Le dernier checkpoint ne couvre que 4.375% des 800k updates et coïncide avec le début de la décroissance du learning rate. Il reste donc impossible de trancher la convergence sur cette fenêtre. La contraction de diversité et la non-monotonie constituent des signaux à surveiller pendant la poursuite ; au meilleur point 5k stratifié/brut du protocole commun, la trace générée vaut 45.899 contre 125.839 pour les images réelles.

Les 20 nouvelles évaluations ont été lancées sur 20 nœuds, huit MI210 par cellule, soit jusqu'à 160 GPU simultanés. Dix-huit cellules ont réussi dans la vague principale ; deux échecs de nœud antérieurs aux calculs scientifiques ont été rejoués à l'identique. Du début de la vague à la fin du retry, le temps mural est de 18 min 26 s. Les cellules réussies totalisent 3 h 01 min 48 s de temps-nœud, soit 24.24 GPU-heures ; les deux tentatives d'infrastructure ajoutent 0.409 GPU-heure, pour 24.649 GPU-heures ordonnanceur.

L'agrégat source a pour SHA-256 :

`22b4559d1112e5b26c03d7be90cf49dda3ab7dca35845d587f012867e8e61c31`

L'inventaire des 24 entrées a pour SHA-256 :

`59166ffebf2ccf3b1dfd15779194069538d0141cfb48e5e00e65f5a605a7e6f1`

11.8.1 EMA plus réactive : decay 0.999

L'EMA 0.9999 de la recette de production évolue très lentement aux premiers checkpoints. Un balayage apparié remplace uniquement cette lecture de poids par l'EMA 0.999 déjà stockée dans les mêmes bundles ; les 12 checkpoints, le NFE, les images de validation et les graines restent identiques. Les résultats sont :

Layout	Checkpoint	FID↓	KID↓	trace
release	5k	397.495891	0.532726858	20.597
release	10k	**375.380476**	**0.493586152**	47.028
release	15k	424.240691	0.580937891	22.663
release	20k	415.438160	0.565465982	23.523
release	25k	429.178707	0.590814588	22.434
release	30k	433.625885	0.598726620	21.401
release	35k	441.583659	0.613409662	20.585
stratifié	5k	**372.514402**	**0.488728271**	31.784
stratifié	10k	430.060340	0.592305142	21.579
stratifié	15k	429.778709	0.591287738	21.862
stratifié	20k	423.023731	0.579221084	22.366
stratifié	25k	423.234762	0.583320045	23.106

Le minimum global EMA 0.999 est donc stratifié 5k : FID 372.514402 et KID 0.488728271. Sur les 12 checkpoints appariés, cette EMA bat l'EMA 0.9999 dans 11 cas sur 12 en FID et 10 cas sur 12 en KID ; le delta moyen est -18.4518 FID et -0.032555 KID. En revanche, elle ne bat les poids bruts que dans 4 cas sur 12 pour les deux métriques et son delta moyen contre le brut vaut $+7.7469$ FID et $+0.012876$ KID. Le decay 0.999 corrige donc largement le retard de l'EMA 0.9999, mais ne change pas la conclusion globale : les poids bruts donnent encore le meilleur point, 336.106247 à 5k stratifié.

Les 12 cellules réussies totalisent 1 h 55 min 11 s de temps-nœud, soit 15.358 GPU-heures avec huit MI210 par cellule. Cinq premières allocations ont échoué avant toute publication (quatre erreurs de prologue et une bibliothèque MIOpen hôte absente) ; elles ajoutent 8 min 23 s de temps-nœud, soit 1.118 GPU-heure. La première vague commence à 20 :09 :35 et le retry finit à 20 :42 :47, soit 33 min 12 s de chaîne murale, contrôle et rescellement du retry compris.

L'agrégat EMA 0.999 a pour SHA-256 :

```
0718e59ea4fdebd02f44f45a8745974a029f712315ee926b69b6c75af5535f38
```

Son inventaire source a pour SHA-256 :

```
f8110dafc0998b2fbf6d5059b9ecddd196ad0a4e372c475848f97f9b2b9d1834
```

11.8.2 Composition NFE aux deux meilleurs checkpoints bruts

Le balayage NFE du checkpoint 25k pouvait masquer un effet propre à un meilleur état du réseau. Une seconde expérience cible donc les deux minima bruts de la courbe : stratifié 5k et release 15k. Les cellules NFE 2, 4, 8 et 16 sont nouvelles ; NFE 1 réemploie exactement les deux reçus authentifiés précédents.

Layout/checkpoint	NFE	FID↓	KID↓	trace
stratifié 5k	1	**336.106247**	0.430355872	45.899
stratifié 5k	2	338.531537	**0.429843203**	35.955
stratifié 5k	4	341.073119	0.434906491	32.752
stratifié 5k	8	342.005880	0.437631602	31.234
stratifié 5k	16	342.865448	0.439818779	30.460
release 15k	1	**374.010005**	**0.491099095**	30.752
release 15k	2	381.014907	0.505169282	28.867
release 15k	4	384.837363	0.513370579	28.284
release 15k	8	385.920757	0.515781720	28.133
release 15k	16	386.498313	0.517048452	28.061

NFE 1 conserve le meilleur FID dans les deux branches. Pour stratifié 5k, NFE 2 améliore seulement le KID de 0.000512669, mais dégrade le FID de 2.425290 points ; de NFE 1 à 16, le FID augmente de 6.759201 points et la trace de covariance diminue de 33.64%. Pour release 15k, FID et KID se dégradent dès NFE 2 ; à NFE 16, les écarts atteignent respectivement +12.488308 et +0.0259494, tandis que la trace baisse de 8.75%.

Ainsi, l'échec à 25k ne venait pas d'un checkpoint exceptionnellement mauvais pour la composition : même aux deux meilleurs checkpoints observés, composer la carte contracte davantage la distribution et ne réduit pas le FID. Le minuscule gain KID à NFE 2 pour stratifié 5k est un compromis entre métriques, pas une amélioration conjointe.

Les huit nouvelles cellules ont utilisé huit nœuds de huit MI210, soit 64 GPU en parallèle. Elles sont toutes terminées sans retry en 11 min 32 s de temps mural. Leur somme vaut 1 h 26 min 38 s de temps-nœud, soit 11.551 GPU-heures allouées.

L'agrégat NFE final, qui indexe chaque source par le couple `(array, task)` afin d'éviter toute collision entre les deux arrays, a pour SHA-256 :

```
933150e3f6199adcc8bceeb11cab8a252105ab50adecbdc2c6260968859483b0
```

L'inventaire byte-à-byte des 30 fichiers sources a pour SHA-256 :

```
38adc3fe242a9c8a43e5c41a539f4a788fdc2762a3e3edd95e21bbe9a167e2d9
```

Temps d'évaluation Slurm. Les 20 cellules Flow finales ont chacune réservé un nœud, huit MI210, 64 CPU et 192 Gio. Elles durent de 9 min 21 s à 11 min 39 s, pour une moyenne de 10 min 21 s. Grâce à l'exécution parallèle (jusqu'à 160 GPU alloués), la vague principale s'étend sur environ 11 min 40 s. L'union de la vague et des retries, de 17 :48 :16 à 18 :08 :39, prend exactement 20 min 23 s de temps mur. La somme des 20 jobs scientifiques réussis est 3 h 27 min 06 s de temps-nœud, soit 27.61 GPU-heures allouées. Deux premières tentatives non scientifiques (une injection de bibliothèque hôte absente, puis une allocation GPU mémoire transitoire) ont échoué avant publication et ont été rejouées à l'identique ; elles ajoutent 9 min 35 s de temps-nœud. En les comptant, la dépense ordonnanceur totale vaut 28.891 GPU-heures. Ces incidents d'infrastructure ne changent aucune valeur scientifique.

La voie GMD distribuée finale a utilisé 16 shards d'une MI210 en parallèle : 10 min 37 s pour l'array, puis 2 min 24 s d'agrégation CPU, soit 13 min 01 s de chaîne murale et 1.68 GPU-heure cumulée. Ce coût n'est *pas* un benchmark de vitesse de génération entre méthodes : la voie GMD réemploie son contrôle brut canonique et partage raw/EMA par shard, tandis que chaque cellule Flow regénère 19,867 PNG sur huit GPU avant FID/KID. Il sépare seulement le temps mur parallèle observé de la somme des allocations GPU.

Les 20 triplets `sample_manifest.json`, `metric_report.json` et `receipt.json` sont sous `runs/DIAGNOSTIC/flowmaps_celeba_direct_rgb_common_fid_kid_v1`. Les artefacts agrégés sont :

— Flow JSON : `array_765925/aggregate/results.json`
SHA-256 : `a9edbd9747de85314e1a34467fc4af2b5defaf213a46de81680efeeb31ce4808` ;
— Flow Markdown : `array_765925/aggregate/results.md`
SHA-256 : `5210bfebe9a77fd5649c03e104e05b60b87fa86440d60ef7bbb3345b33592d64` ;
— GMD JSON distribué, SHA-256 :
`76004d719bd86183b3c2fdfb48922befe3f6e008f7f6c351c5dc357c284f66e3`.

11.9 Effet causal de ConvNeXt dans le screen RGB

Le screen ConvNeXt conserve le même train local de 25,000 images, le même DiT-B, le même checkpoint MAE, les mêmes RNG, supports et banques, les mêmes températures, l'optimiseur, le warmup et l'EMA. L'unique intervention préenregistrée est l'ajout de 13 familles ConvNeXt-V2 Base gelées aux 82 familles MAE. Le résultat primaire était fixé avant entraînement : EMA à l'update 10,000, NFE 1, seed 42,001 et 4,999 images.

Features gelées	FID↓	KID↓	trace générée
MAE seul	53.262069	0.0446405	—
MAE + ConvNeXt-V2 Base	**18.886636**	**0.0088412**	107.463

Le FID diminue de 64.54% et le KID de 0.0357993 en valeur absolue. Les seuils préenregistrés étaient FID $\leq$ 50.598966 et KID $<$ 0.0446404852 : les deux passent, et l'agrégateur strict rend **GO**. Les 4,999 PNG sont tous présents, sans recouvrement exact avec la référence ; le job d'évaluation `759627` est terminé `COMPLETED/0:0`.

Ce gain répond directement au diagnostic de la littérature : en haute dimension, la qualité de l'espace de features utilisé par le drifting est déterminante. Il démontre ici que le GMD peut apprendre des visages directement en RGB sans VAE. Il ne constitue cependant qu'une graine sur un holdout de développement déjà consulté. La confirmation propre doit utiliser le train et la validation officiels, puis n'ouvrir le test qu'une seule fois.

Le coût est réel : la boucle complète prend 24,990.854 s, soit 2.4991 s/update, contre 6,142.319 s, soit 0.6142 s/update, pour le screen MAE seul. L'ajout de ConvNeXt multiplie donc le coût mesuré par 4.07. Les temps mur Slurm sont respectivement 7 h 01 min 09 s et 1 h 45 min 28 s sur huit MI210.

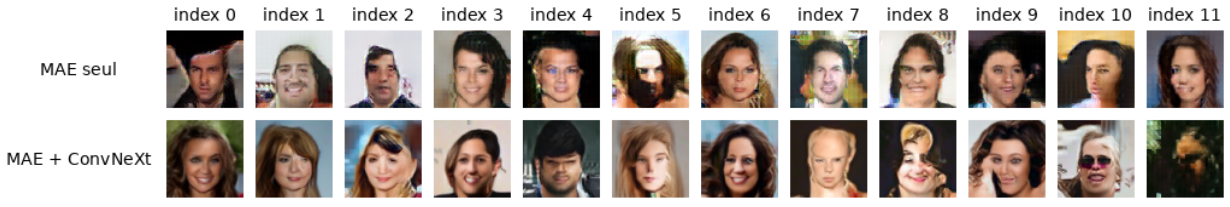


FIGURE 3 – Comparaison qualitative causale à l'update 10k, poids EMA et NFE 1. Les deux lignes utilisent exactement les indices 0–11, donc les mêmes graines 42,001–42,012. Ces indices consécutifs ont été fixés avant inspection ; aucune image n'a été classée ni sélectionnée selon sa qualité. Le rendu colle les PNG 64x64 natifs sans resampling. La provenance complète est enregistrée dans le sidecar JSON, et le PNG final a pour SHA-256 `68ed3b3ad1c6bc73a38ab2faac3f706ac1c1da6e8b2ec2342163642f25671a85`.

11.10 Diagnostic post-hoc du noyau GMD

Un outil séparé reconstruit exactement les affinités et l'énergie de la loss officielle. Sur les cas testés, l'écart absolu d'énergie reste inférieur à 1.2×10^{-8}, et les 19 tests ciblés passent. Pour le contrôle RGB à 10k, il reprend le support d'entraînement exact : 64 images générées, 128 positifs et 32 négatifs de poids nul. La moyenne de sept familles donne :

T	ESS attr.	ESS rép.	plancher attr.	plancher rép.	cosinus signé
0.20	69.03/128	35.00/64	2.12%	2.26%	-0.950
0.05	14.66/128	9.06/64	12.54%	12.29%	-0.804
0.02	14.03/128	10.70/64	29.43%	30.49%	-0.671

Les petites températures rendent donc le voisinage très local et, à $T = 0.02$, environ 30% de la masse vient du plancher d'affinité officiel. Mais remplacer les 64 images générées par 64 vrais visages donne presque les mêmes valeurs ; les rapports d'énergie généré/réel–réel ne sont que 1.18, 1.15 et 1.05. Le diagnostic ne révèle donc pas d'effondrement grossier du noyau propre au générateur. Il ne prouve ni l'égalité des distributions ni la qualité suffisante des features : il est post-hoc, emploie des PNG quantifiés, des banques statiques et seulement 7 des 82 familles RGB. Deux familles latentes d'écart-type sur une carte 1×1 sont en outre exactement nulles ; elles seront seulement candidates à une ablation future.

11.11 Reprise de la flow map : pilotes D2 et D4

La branche moderne apprend une flow map LSD à deux temps. D2 reprend exactement le checkpoint brut 30k de cette flow map et ajoute uniquement un faible ancrage GMD terminal, augmenté linéairement jusqu'à 10% pendant les updates 30k–40k. Après la clôture de D2, D4 reprend séparément ce même état 30k et conserve tout à l'identique sauf la dose terminale, fixée à 5% de la calibration égal-RMS. Le contrôle apparié donne :

NFE	LSD brut	D2 brut	D4 brut	LSD EMA	D2 EMA	D4 EMA
1	37.625	**33.403**	34.328	34.130	**32.693**	33.308
4	32.520	**30.769**	32.164	28.388	28.154	**28.153**
16	31.503	**30.404**	31.389	**27.731**	27.868	27.737

D2 améliore donc le contraste brut à toutes les NFE, de 11.22% à NFE 1 et 3.49% à NFE 16. L'EMA est presque inchangée aux grandes NFE et devient même légèrement moins bonne à NFE 16. Le coût observé passe de 0.1833 à 0.3684 seconde/update.

D4 conserve le gain brut : son FID descend monotoniquement de 34.328 à 31.389. Sur son contraste EMA primaire, il améliore LSD pur de 2.409% à NFE 1 et de 0.188% à NFE 8. À NFE 16, il vaut toutefois 27.737089 contre 27.730546 en FID, et 0.021096889 contre 0.021082819 en KID. Il échoue donc exactement aux deux inégalités strictes de cette cellule et reçoit `NO_GO`. Son temps observé est 0.3300 seconde/update, soit 1.80× le LSD pur. D2 et D4 exécutent le même graphe coûteux ; leur écart de temps ne peut pas être attribué causalement à la division de lambda. Les deux pilotes sont mono-graine sur le holdout local réutilisé, pas une preuve générale.

11.12 E10 + transition GMD locale vraie courte

Idée et objectif exact

Cette campagne corrige le défaut de l'expérience locale précédente : la loss locale n'est plus chargée d'apprendre seule une trajectoire. Le modèle est forké exactement depuis le checkpoint Flow–GMD E10 à 5,000 updates, déjà scalable, avec restauration du modèle, de l'EMA, de l'optimiseur, des banques, du flux de données et des états RNG. La supervision terminale composée reste $K \in \{1, 2\}$, tiré à probabilités $1/2, 1/2$, E10 reste pondéré par 10 et le semigroup reste nul.

Pour un temps de départ a, on construit la source arrêtée et une vraie transition courte :

$$X_a = \mathrm{stopgrad}(\Phi_\theta(z, 0, a)), \qquad u = a + 0.05, \qquad Y_{a\to u} = \Phi_\theta(X_a, a, u).$$

Si q_f est l'échelle officielle de la famille de features f, et $F_f(X_a)$ la force GMD détachée calculée sur la géométrie de X_a, la loss locale retenue est

$$\mathcal{L}_{\mathrm{tr,loc}} = \frac{1}{2} \sum_f \left\| \frac{f(Y_{a\to u})/q_f - f(X_a)/q_f}{\alpha_a} - F_f(X_a) \right\|^2, \qquad \alpha_a = \frac{0.05}{1-a}.$$

L'objectif total d'une update est donc

$$\boxed{\mathcal{L} = \mathcal{L}_{\text{GMD terminale},K} + 10\mathcal{L}_E + 0.005\mathcal{L}_{\mathrm{tr,loc}}.}$$

Les quatre couples équiprobables (a, u, α_a) sont

$$(0.1, 0.15, 0.05556),\ (0.5, 0.55, 0.10),\quad (0.8, 0.85, 0.25),\ (0.9, 0.95, 0.50).$$

Le graphe calcule également la vue $\Phi_\theta(z, 0, u)$, nécessaire à l'ablation compute-matched, mais son poids dans la recette gagnante est exactement zéro : seul le bras transition $a \to u$ reçoit le gradient local. Il n'y a ici ni VAE ni latent ; les 95 familles gelées MAE–82+ConvNeXt–13 opèrent directement sur les images RGB.

Pourquoi 500 updates à l'ancien learning rate sont rejetées

Le premier écran compare cinq forks appariés, chacun prolongé de 500 updates à 2×10^{-5}. Chaque cellule est FID/KID sur la seed de génération 42,001 :

Branche	NFE 1	NFE 2, $p = 1.5$	NFE 4, $p = 3.5$	NFE 16, $p = 16$
Contrôle C0	8.328346/0.00344395	7.952627/0.00304023	7.953242/0.00302969	7.964870/0.00303357
Origine seule, 0.005	9.674602/0.00438026	9.630656/0.00385970	9.642986/0.00383678	9.629621/0.00385348
Transition seule, 0.005	**8.209793/0.00337944**	**7.777963/0.00296097**	**7.763144/0.00293893**	**7.769251/0.00294446**
Deux vues, 0.005	8.499163/0.00356758	8.135132/0.00313005	8.143765/0.00309302	8.148990/0.00311683
Deux vues, 0.0025	8.802382/0.00383842	8.496546/0.00337194	8.530134/0.00338547	8.534055/0.00338903

La transition seule est meilleure que le contrôle de 500 updates à toutes les NFE, tandis que la vue origine est clairement antagoniste. Mais les cinq forks sont moins bons en absolu que le checkpoint E10–5k de départ. La réponse expérimentale correcte est donc une micro-continuation transition-only, avec un learning rate quatre fois plus faible, et non un entraînement plus long.

Résultat retenu après 50 updates

Quatre nouveaux forks appariés font exactement 50 updates à 5×10^{-6} : un contrôle sans terme local, puis $\lambda_{\text{local}} \in \{0.001, 0.0025, 0.005\}$. Sur la seed 42,001, le poids 0.005 est le seul qui bat E10–5k à la fois en FID et en KID aux NFE 1 et 2. Il est donc le seul candidat confirmé. Les moyennes ci-dessous utilisent trois seeds de génération, 42,001–42,003, avec écart-type échantillon :

NFE	Variante	FID moyen ± SD	KID moyen ± SD
1	E10–5k	7.864869 ± 0.001716	0.002880292 ± 0.000005290
1	contrôle +50	7.819203 ± 0.001141	0.002861842 ± 0.000014147
1	**local 0.005 +50**	**7.801172 ± 0.000774**	**0.002840111 ± 0.000013908**
2	E10–5k	7.586158 ± 0.002586	0.002659833 ± 0.000013027
2	contrôle +50	7.558992 ± 0.002361	0.002663675 ± 0.000015168
2	**local 0.005 +50**	**7.557358 ± 0.000590**	**0.002651190 ± 0.000008817**
16	E10–5k	7.585536 ± 0.001093	0.002654469 ± 0.000013847
16	contrôle +50	7.558154 ± 0.001139	0.002663733 ± 0.000005106
16	**local 0.005 +50**	**7.549949 ± 0.001001**	**0.002641553 ± 0.000008093**

Face à E10–5k, le candidat améliore FID et KID dans 3/3 seeds aux NFE 1, 2 et 16. À NFE 4 sur la seed 42,001, il atteint 7.548705/0.00263713, contre 7.555303/0.00265134 pour le contrôle et 7.588004/0.00264506 pour E10–5k.

Pour attribuer le gain, il faut comparer local 0.005 au contrôle qui reçoit les mêmes 50 updates. Les différences appariées local moins contrôle sont :

- NFE 1 : -0.018031 ± 0.000647 FID et $-0.000021730 \pm 0.000002124$ KID, amélioration 3/3 ;
- NFE 2 : -0.001634 ± 0.002704 FID, amélioration seulement 2/3, mais $-0.000012485 \pm 0.000006405$ KID, amélioration 3/3 ;
- NFE 16 : -0.008205 ± 0.001126 FID et $-0.000022180 \pm 0.000003040$ KID, amélioration 3/3.

Le faible learning rate et les 50 updates expliquent donc la majorité du gain FID absolu, particulièrement à NFE 2. La transition locale apporte un signal causal fort sur le KID, sur NFE 1 et sur NFE 16 ; son effet FID à NFE 2 est trop petit pour être dit robuste seed par seed. La conclusion est robuste à trois seeds d'*évaluation*, mais repose encore sur une seule seed d'*entraînement*.

Temps, validation et artefact

Sur huit MI210, la médiane stabilisée vaut 2.236 s/update pour la recette locale, contre 1.086 s/update pour E10 seul, soit un facteur 2.06×. Le contrôle compute-matched vaut 2.256 s/update. Le job court gagnant dure 10 min 04 s au mur, dont environ 2 min 28 s dans l'invocation d'entraînement ; les coûts fixes de chargement, du prologue distribué et de sauvegarde dominent donc ce budget de 50 updates. Le pic par GPU est 7.23 Go alloués et 7.94 Go réservés. Les cinq écrans de 500 updates durent 26–29 minutes chacun.

Les 120 tests ciblés passent, ainsi que les validations de syntaxe Python et Slurm. Les quatre entraînements courts ont un strict reload valide. Les 24 évaluations scientifiques retenues sont terminées : chacune emploie les 19,867 références officielles, 19,867 générations de hashes pixels uniques, huit GPU et le protocole FID/KID commun. Deux tentatives arrêtées au préflight mémoire avant génération ont été remplacées et exclues. L'artefact raw sélectionné a pour SHA-256 `9c82773234ed62c375b7a193b2a3a8debcfcf3c67bfa2db509d32714a0d559d1`.

11.13 Priorités expérimentales après l'audit

1. Répliquer d'abord la micro-continuation E10–5k + transition locale 0.005 avec au moins deux nouvelles seeds d'entraînement, en conservant le contrôle apparié +50 updates à 5×10^{-6}. C'est la preuve manquante avant de généraliser le gain causal observé sur trois seeds de génération.
2. Poursuivre le layout `stratifié` comme bras principal conforme à l'intention 75/25, tout en gardant `release` comme contrôle exact du code publié. Le résultat à 35k est trop précoce pour arrêter au motif que ń plus d'entraînement ne sert pas ż.
3. Pour Flow Maps, suivre l'EMA 0.9999 avec l'évaluateur papier tous les 10k updates, donc aux suffixes pairs. Utiliser FID-10k pour filtrer, puis réserver le FID-50k aux candidats prometteurs et sélectionner un checkpoint distinct pour chaque NFE, comme dans le papier.
4. Employer comme gate de santé le retour d'un bénéfice de composition : dans le papier, NFE 2/4/8/16 améliore systématiquement NFE 1. Si les checkpoints postérieurs au début de décroissance continuent de se contracter quand NFE augmente, diagnostiquer la loss LSD, le JVP et le sharding avant de consommer aveuglément tout le budget.
5. Pour GMD RGB, prioriser MAE+ConvNeXt, déjà validé causalement, terminer au moins 100k updates, comparer poids bruts et EMA, puis tester l'ablation inconditionnelle sans négatifs fixes. L'augmentation du support vient après ces facteurs mieux étayés.
6. Pour une comparaison GMD–Flow Maps finale, imposer aux deux méthodes le même crop cible, la même référence réelle, le même Inception, 50k générations et une politique de graines identique ; rapporter updates, exemples vus, temps mur et GPU-heures.

12 Diagnostics : que résout réellement la méthode ?

Sur les derniers 10% des enregistrements d'entraînement, Core C donne :

Diagnostic	Moyenne ± écart-type sur les graines
ESS attraction	129.554 ± 1.992
ESS répulsion	48.851 ± 2.130
RMS de la vitesse	0.024358 ± 0.000215
Résidu WGF origine relatif	1.0408 ± 0.0313
Résidu WGF local relatif	1.1364 ± 0.0657
Erreur relative moyenne de transition, EMA	0.18388 ± 0.02288

Des résidus WGF proches de 1 ne décrivent pas une résolution précise de l'équation de gradient de Wasserstein. La bonne formulation est : le KDE/WGF fournit un enseignant directionnel imparfait, l'endpoint fixe la destination, et la composition apprend une transition réutilisable. Une petite erreur de composition ne suffit pas non plus à garantir de bonnes images ; la qualité doit être évaluée séparément par FID, KID et inspection visuelle.

13 Lien avec MNIST et les mélanges de Gaussiennes

CelebA n'utilise pas la même valeur numérique de bandwidth que les expériences précédentes, car les coordonnées et les échelles diffèrent :

Expérience	Espace	VAE	Bandwidth retenue
Mélange de Gaussiennes	$\mathbb{R}^2$	non	$h = 1$, fixe
MNIST	pixels, $\mathbb{R}^{784}$	non	$h = 2.5$, fixe
CelebA latent	$\mathbb{R}^{256}$	oui, gelé	$h = 3$, fixe

Pour le mélange séparé, une médiane automatique avait été essayée puis retirée car elle était trop large et créait un pont entre les modes. Pour MNIST, $h = 1$ était trop local et $h = 3$ trop lisse ; $h = 2.5$ a été retenu. Ces valeurs ne sont pas directement comparables entre datasets.

14 Conclusions scientifiquement défendables

Ce que les résultats soutiennent.

- Le KDE–WGF latent est déjà beaucoup plus efficace que sa version pixel dans les pipelines historiques testés.
- À un appel, la flow map Core C améliore ce baseline KDE–WGF latent pour les trois graines observées.
- Réutiliser la flow map quatre fois apporte une amélioration forte et cohérente par graine.
- Seize appels n'améliorent plus le FID moyen et contractent davantage la diversité : NFE 4 est le point de fonctionnement empirique.
- La régularisation eulérienne B augmente le coût sans avantage de qualité résolu ; l'objectif minimal Core C est donc retenu.
- Le GMD canonique avec MAE gelé apprend bien sur les images locales : FID 37.413 en latent à 30k, et 53.262 en RGB direct sans VAE dès 10k.
- Sur la validation officielle complète, le même principe RGB sans VAE atteint à 25k un FID de 45.716 en brut et 37.943 en EMA. L'EMA améliore nettement le résultat, mais l'inspection révèle encore des artefacts fins ; le drifting fonctionne donc sans être encore une recette forte.
- Au checkpoint GMD 50k, le protocole distribué calibré donne un FID de 40.095945 en brut et 35.230066 en EMA. Dans le même espace RGB et sur les mêmes 19,867 références, le meilleur Flow Maps 25k reste à 374.801540 (KID 0.500694628). Les cinq NFE brutes sont numériquement invariantes : augmenter le nombre de compositions ne répare pas ce checkpoint.
- La courbe Flow Maps à NFE 1 améliore ce minimum observé à 336.106247 (KID 0.430355872), avec le layout stratifié brut à 5k. Les trajectoires 5k–35k sont fortement non monotones, mais cette fenêtre ne couvre que 4.375% du budget et ne réfute donc pas le sous-entraînement ; elle interdit seulement de supposer une amélioration régulière entre checkpoints précoces.
- L'EMA 0.999 est meilleure que l'EMA 0.9999 dans 11 cas sur 12 en FID, mais reste moins bonne que les poids bruts en moyenne. Aux deux meilleurs checkpoints bruts, NFE 2/4/8/16 ne réduit jamais le FID et contracte progressivement la diversité ; la composition n'est donc pas le remède manquant dans cette recette directe-RGB.
- L'ablation causale RGB ajoute seulement 13 familles ConvNeXt gelées et abaisse le FID 10k de 53.262 à 18.887 ; sa gate préenregistrée est GO. La qualité des features, et non le VAE seul, était donc un verrou majeur du screen direct.
- Dans le pilote D2 strictement apparié, le faible ancrage GMD améliore la flow map brute à toutes les NFE observées.
- D4 divise cet ancrage par deux et conserve le gain brut, mais manque de très peu ses deux portes EMA à NFE 16 ; son verdict verrouillé est `NO_GO`.
- Le Flow–GMD E10 direct-RGB est réellement scalable : après une micro-continuation de 50 updates avec transition locale 0.005, il atteint un FID moyen de 7.8012 à NFE 1 et 7.5499 à NFE 16. Il bat E10–5k en FID et KID dans 3/3 seeds de génération aux NFE 1, 2 et 16. Face au contrôle apparié +50, le gain local est robuste aux NFE 1 et 16 et sur le KID aux trois budgets.
- Le contrôle réel–réel du noyau ressemble au contrôle généré–réel : aucune erreur grossière propre au générateur n'apparaît dans ces statistiques, même si le plancher pèse environ 30% à $T = 0.02$.

Ce que les résultats ne prouvent pas.

- Ils ne prouvent pas que le latent seul cause tout le gain, car plusieurs éléments du protocole changent par rapport à l'écran pixel.
- Ils ne prouvent pas une supériorité générale sur toutes les flow maps, tous les datasets ou l'état de l'art.
- Ils ne montrent pas une résolution exacte d'une PDE WGF.
- Trois graines ne suffisent pas à conclure que B et C diffèrent dans la population.
- L'ensemble d'évaluation est un développement réutilisé pour la sélection, pas un test externe vierge.
- Les lignes GMD, Flow Maps direct-RGB, ConvNeXt, D2 et D4 sont encore mono-graine. GMD 25k/50k et la matrice Flow Maps 25k disposent de mesures sur la validation officielle, mais aucune n'est confirmée sur le test officiel, plusieurs graines ou ImageNet.
- La micro-continuation E10 + transition locale dispose de trois seeds de génération, mais d'une seule seed d'entraînement. Elle ne prouve donc pas encore que le gain local se répète entre entraînements indépendants.
- Le grand écart GMD–Flow du protocole commun n'est pas une comparaison compute-normalisée : les checkpoints sont à 50k et 25k, et les architectures, objectifs, exemples vus et budgets GPU diffèrent.
- Le diagnostic de noyau post-hoc n'isole pas causalement le FID et ne couvre que 7 des 82 familles RGB sur des PNG quantifiés.

La formulation exacte de la confirmation historique est :

> Dans le pipeline CelebA-64 testé, un VAE préentraîné gelé fournit un espace de 256 dimensions dans lequel une flow map à deux temps est entraînée uniquement avec un endpoint de drifting, deux résidus WGF et une contrainte de composition. Sur trois graines, l'objectif minimal atteint un FID de 45.762 ± 1.513 à NFE 4, contre 66.020 ± 1.002 pour le KDE–WGF latent à un appel. Le gain à NFE 4 s'accompagne d'un coût d'entraînement moyen de 5 min 28 s contre 3 min 00 s dans le trainer sur huit MI210. Ces résultats valident le pipeline étudié, sans établir une résolution exacte de la WGF ni isoler causalement l'effet du latent.

L'état actuel va plus loin, sans encore constituer une conclusion finale de papier : la loss GMD canonique a abaissé le FID dev latent à 37.413 ; en RGB direct et sans VAE, le GMD atteint 35.230066 en EMA à 50k sur la validation officielle complète. Dans le nouveau protocole commun, la Flow Maps RGB 25k reste à 374.801540 au mieux, malgré le layout stratifié et le balayage de NFE. La trajectoire de checkpoints trouve 336.106247 à 5k, mais oscille ensuite jusqu'à 35k. Comme cette borne ne représente que 4.375% des 800k updates et le début de la décroissance du learning rate, le sous-entraînement demeure une explication majeure et n'est pas testé par cette courte fenêtre. Sa non-monotonie indique seulement qu'une poursuite sans gates intermédiaires n'offre aucune garantie. L'EMA 0.999 corrige une partie du retard de l'EMA 0.9999 sans battre le meilleur brut, et le balayage ciblé montre que composer jusqu'à NFE 16 augmente le FID aux deux meilleurs checkpoints tout en réduisant la trace de covariance. L'ajout causal de ConvNeXt atteint par ailleurs 18.887 à 10k sur le holdout de développement. L'hybride D2 améliore aussi causalement le checkpoint LSD brut partagé. D4 montre que diviser sa dose par deux réduit presque entièrement la petite dégradation EMA aux grandes NFE, sans satisfaire exactement la porte NFE 16. Séparément, le nouveau Flow–GMD E10 direct-RGB atteint 7.8012 ± 0.0008 à NFE 1 et 7.5499 ± 0.0010 à NFE 16 après seulement 50 updates à faible learning rate avec transition locale. L'ablation compute-matched attribue la majorité du gain FID absolu à la continuation et attribue à la loss locale des gains causaux robustes sur le KID ainsi qu'aux NFE 1 et 16. Cette conclusion est confirmée entre seeds de génération, pas encore entre seeds d'entraînement. La prochaine preuve requiert le train officiel complet, la sélection sur validation et plusieurs graines. Une affirmation finale devra soit rapporter transparentement le test CelebA comme déjà exposé historiquement, soit employer un nouveau holdout externe réellement

intact.

A Valeurs par graine

Table 8 – FID par graine pour la comparaison principale.

Graine	KDE–WGF, NFE 1	C, NFE 1	C, NFE 4	C, NFE 16
41	66.724	61.886	46.459	46.509
42	64.872	60.874	44.026	45.310
43	66.463	61.907	46.802	46.484
Moyenne	66.020	61.556	45.762	46.101

Les trois graines améliorent le FID de Core C entre NFE 1 et NFE 4. Entre NFE 4 et NFE 16, les signes sont mixtes, ce qui confirme le plateau moyen.

B Artefacts sources et reproduction

Les résultats confirmatoires principaux proviennent de :

```
runs/celeba_latent_wgf/latent_final_confirmation_v12/
  evaluation/final_results.json
  evaluation/final_results.md
  training_summary.json
  training_summary.md
```

Les logs de chaque entraînement sont stockés sous :

```
runs/celeba_latent_wgf/latent_final_confirmation_v12/runs/*/metrics.jsonl
```

Les résultats historiques pixel sont stockés sous :

```
runs/celeba_fid/pixel/
runs/celeba_wgf/pixel_screen_v1/training_summary.json
```

Les fichiers d'implémentation principaux sont :

```
src/celeba_latent.py
src/wgf.py
src/official_drifting.py
src/flow_map_self_distillation.py
celeba_latent_flow.py
experiments/cache_celeba_latents.py
experiments/prepare_official_celeba64.py
experiments/run_celeba_latent_final_confirmation.py
experiments/run_celeba_latent_final_evaluation.py
```

La filiation et le futur protocole officiel sont audités dans `CELEBA_DATASET_EVALUATION_AUDIT.md`. Les résultats GMD et les écarts exacts avec la littérature sont centralisés dans `DRIFTING_CELEBA_CORRECTION.md`. Le diagnostic de noyau et ses rapports sont décrits dans `OFFICIAL_GMD_KERNEL_DIAGNOSTIC.md` et `runs/celeba_diagnostics/official_gmd_kernel/`. Les résultats D2 proviennent de `runs/celeba_latent_lsd/lsd_independent_std1_base256_seed42_lr003_`

ramped_gmd10pct_40k_v1 et de son contrôle pur apparié. D4 provient de runs/celeba_latent_lsd/lsd_independent_std1_base256_seed42_lr003_ramped_gmd5pct_40k_d4_v1. Son protocole pré-résultat est CELEBA_LSD_GMD_D4_HALF_ANCHOR_PROTOCOL.md ; le contrôle terminal V12 en lecture seule a revalidé les dix cellules, n'a écrit aucun résultat et a retourné NO_GO. Le SHA-256 de sa trace interne est a703ff0ef6f13fbd932f6045c73f7af984134d6e2faf00059676bf0d773e61ec.

La campagne Flow–GMD E10 + transition locale courte est reproductible depuis :

```
experiments/celeba_flow_gmd_20260915/train_e10_local_gmd.py
src/celeba_gmd_e10_local_rollout.py
src/celeba_gmd_local_two_view.py
src/celeba_gmd_local_training.py
runs/celeba_flow_gmd_20260915/e10_local_training/
  lr5e6_l_l005_w000100_step5050_v1/
    flow_raw_step_00005050.pt
    artifact_manifest_step_00005050.json
runs/celeba_flow_gmd_20260915/evaluation/
  lr5e6_l005_step5050_raw_nfe*_confirm_v1/
```

Le checkpoint parent E10–5k est runs/celeba_flow_gmd_20260914/structural_training/struct500_e10_k12_20260914_0408/checkpoints/checkpoint_step_00005000.pt. Le rapport Markdown exhaustif, avec chaque lien de métrique, est POINT_ENTRAINEMENTS_20260914.md.

Le résultat causal ConvNeXt est scellé dans :

```
runs/celeba_pixel_gmd/generator/
  direct_rgb_gmd_screen_ditb_prodmae_nondec_convnextbase_fp32_seed42_10k_v1/
  evaluation/convnext_terminal_ema10k_nfe1_4999_seed42001_v1/
    aggregate_strict_v1/summary.json
```

Le SHA-256 du résumé est 73127f80e2fc0f2e2abf317e014d6a88166d382b398a886678a8662eec103b91. Le protocole d'évaluation est CELEBA_PIXEL_GMD_CONVNEXT_SCREEN_EVALUATION_PROTOCOL_V1.md.

Le MAE entraîné sur le vrai train officiel se trouve sous runs/celeba_pixel_gmd/pixel_mae_official_train_base64_seed42_192ep_v1. Le futur contraste officiel ConvNeXt est volontairement non exécutable tant que le baseline à budget égal n'est pas mesuré ; ses invariants sont fixés dans CELEBA_PIXEL_GMD_CONVNEXT_OFFICIAL_CAUSAL_CONFIRMATION_PREPROTOCOL_V1.md.

La préparation du cache s'exécute par exemple avec :

```
python experiments/cache_celeba_latents.py \
  --data-root data/celeba64 \
  --vae-model data/models/sd-vae-ft-mse \
  --output data/celeba64_latents_sdvae_ft_mse.pt
```

Le protocole confirmatoire lance neuf entraînements : trois méthodes (Core C, B, KDE–WGF) croisées avec trois graines. L'évaluation finale valide 21 cellules : C et B à NFE 1/4/16, plus le KDE–WGF à NFE 1, pour chacune des trois graines.

C Note de provenance sur le cache historique

Le cache utilisé par la confirmation enregistre le modèle, le facteur d'échelle et la règle d'encodage, mais il est antérieur à l'enregistrement des hashes exacts des fichiers du VAE. Deux réencodages

contemporains ont donc été effectués. Les tenseurs ne sont pas identiques octet par octet ; l'écart historique–attesté vaut environ

$$\mathrm{MAE} = 1.120 \times 10^{-7}, \qquad \mathrm{RMSE} = 1.660 \times 10^{-7}, \qquad \max = 1.457 \times 10^{-5}.$$

Ces écarts donnent un ordre de grandeur numérique. Ils ne prouvent ni l'identité du cache, ni une reproduction bit à bit, ni l'invariance des résultats aval. L'audit complet est disponible dans `runs/celeba_latent_wgf/latent_cache_attestation_v12/report.md`.

Références

[1] E. Parzen. On estimation of a probability density function and mode. *The Annals of Mathematical Statistics*, 33(3) :1065–1076, 1962.

[2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser et B. Ommer. High-resolution image synthesis with latent diffusion models. *CVPR*, 2022.

[3] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler et S. Hochreiter. GANs trained by a two time-scale update rule converge to a local Nash equilibrium. *NeurIPS*, 2017.

[4] M. Bińkowski, D. J. Sutherland, M. Arbel et A. Gretton. Demystifying MMD GANs. *ICLR*, 2018.

[5] Z. Liu, P. Luo, X. Wang et X. Tang. Deep learning face attributes in the wild. *ICCV*, 2015.

[6] Stability AI. `sd-vae-ft-mse`, modèle et fiche descriptive, 2022. https://huggingface.co/stabilityai/sd-vae-ft-mse.

[7] C. Deng et al. Generative Modeling via Drifting. *arXiv :2602.04770*, 2026. https://arxiv.org/abs/2602.04770.

[8] Y. Li et al. A Long–Short Flow-Map Perspective for Drifting Models. *arXiv :2602.20463*, 2026. https://arxiv.org/abs/2602.20463.

[9] N. M. Boffi, M. S. Albergo et E. Vanden-Eijnden. How to build a consistency model : Learning flow maps via self-distillation. *arXiv :2505.18825v2*, 2025. https://arxiv.org/abs/2505.18825.